GP 3

Statistics in Data Analysis

Team 36

Part 1

A/B-test: Landing page

EDA

Data

- User ID
- Timestamp
- Group
- Landing page
- Converted

EDA

Data

- User ID
- Timestamp
- Group
- Landing page
- Converted

Convertion rate

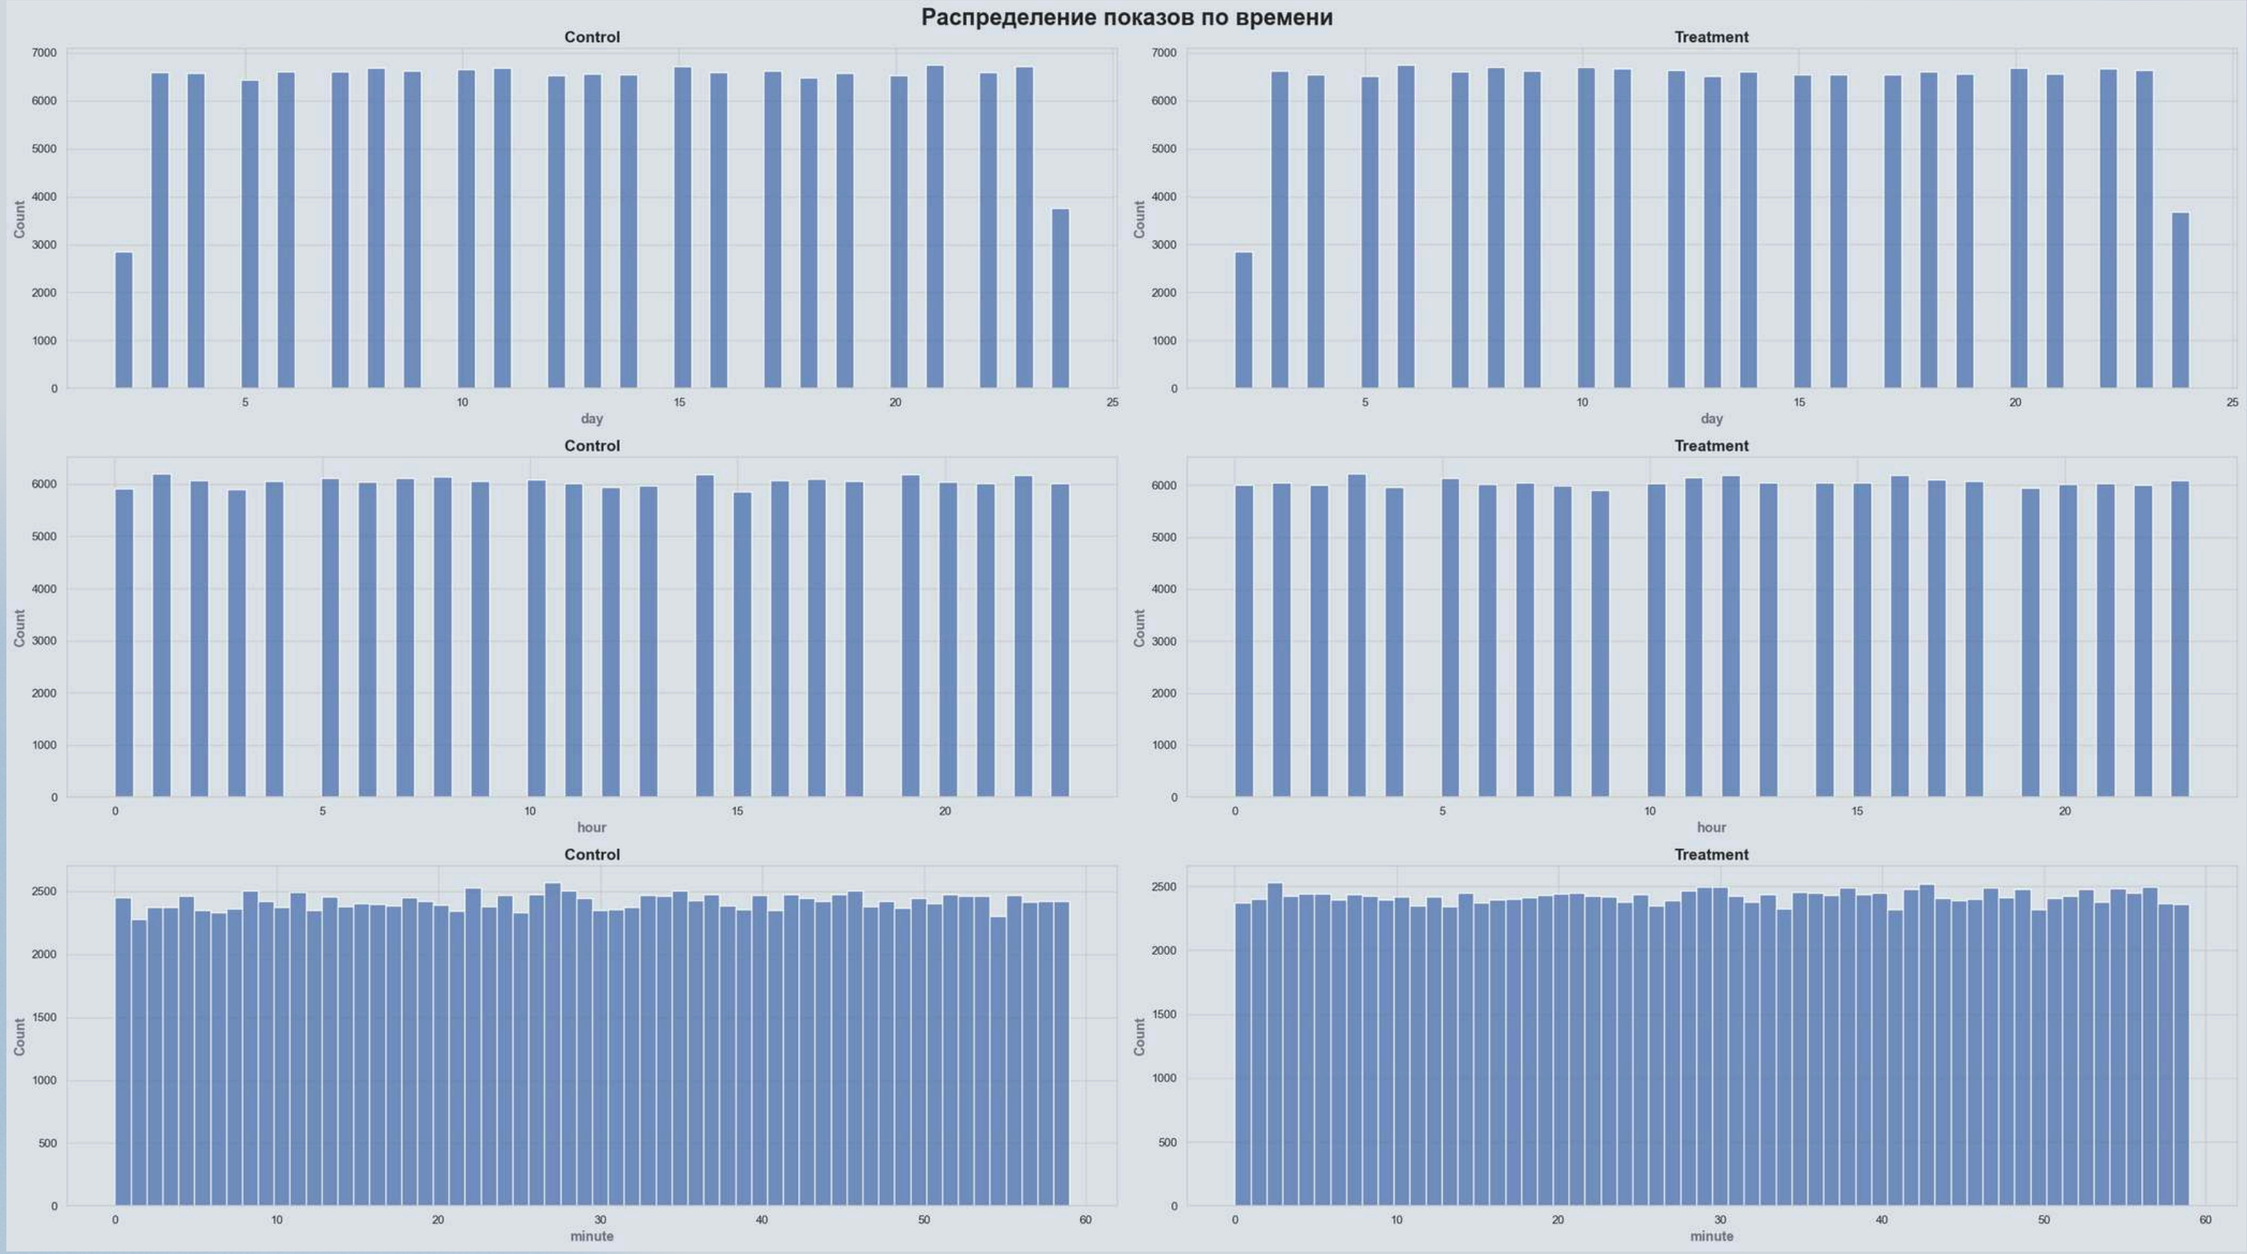
Распределение показов по времени
Control
Treatment
Count
day
hour
minute

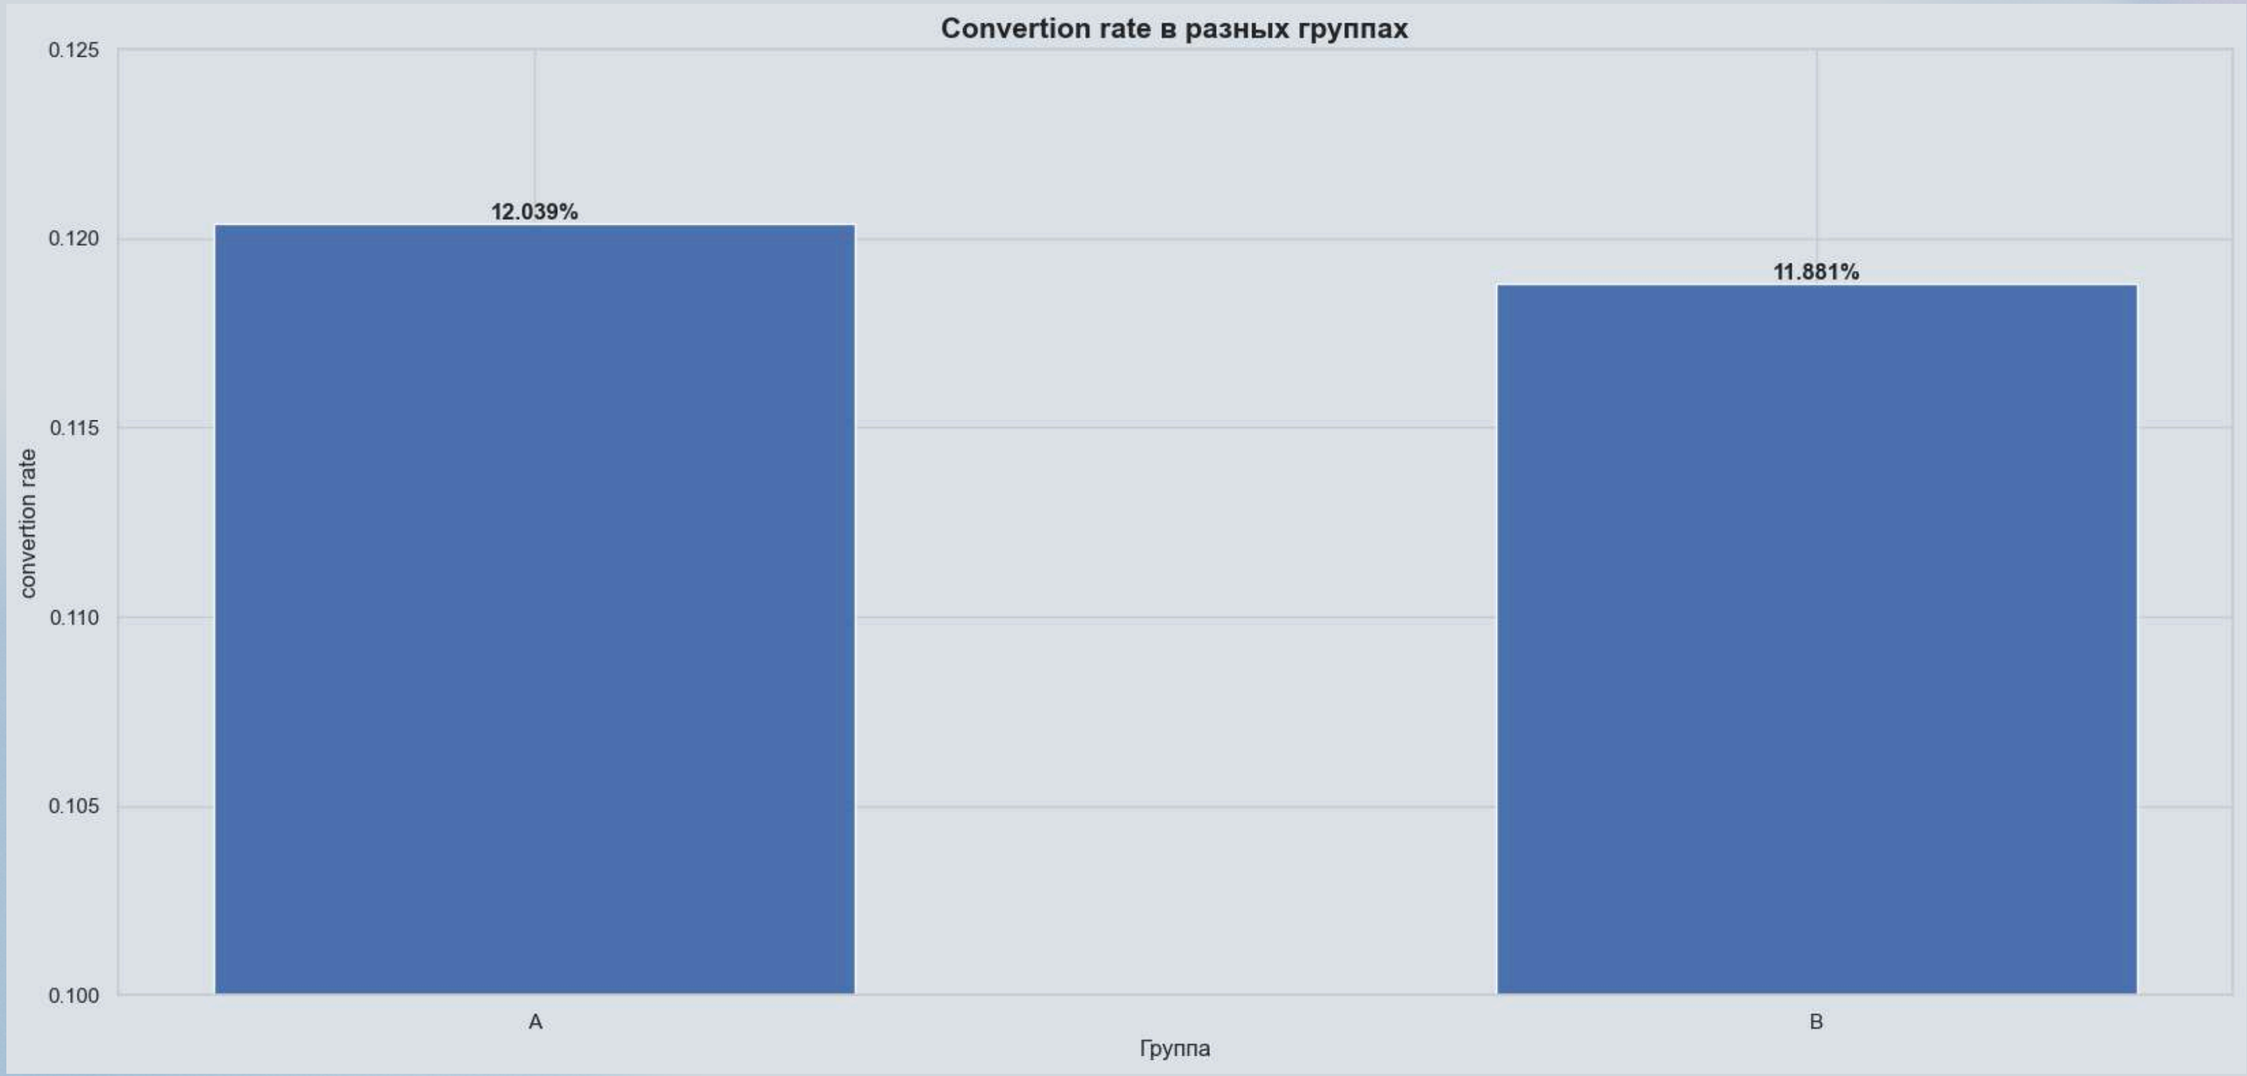
Convertion rate в разных группах
0.125
0.120
0.115
0.110
0.105
0.100
convertion rate
12.039%
11.881%
A
B
Группа

Hypotheses

H0 Показатели конверсии в контрольной и тестовой выборках равны

H1 Показатели конверсии в контрольной и тестовой выборках отличаются

Z-тест для пропорций

```
Конверсия в контрольной группе: 0.12039
Конверсия в тестовой группе: 0.11881
```

```
Результаты z-теста пропорций с альтеративой two-sided
Статистика теста: 1.3109241984234394
p-value: 0.18988337448195103
```

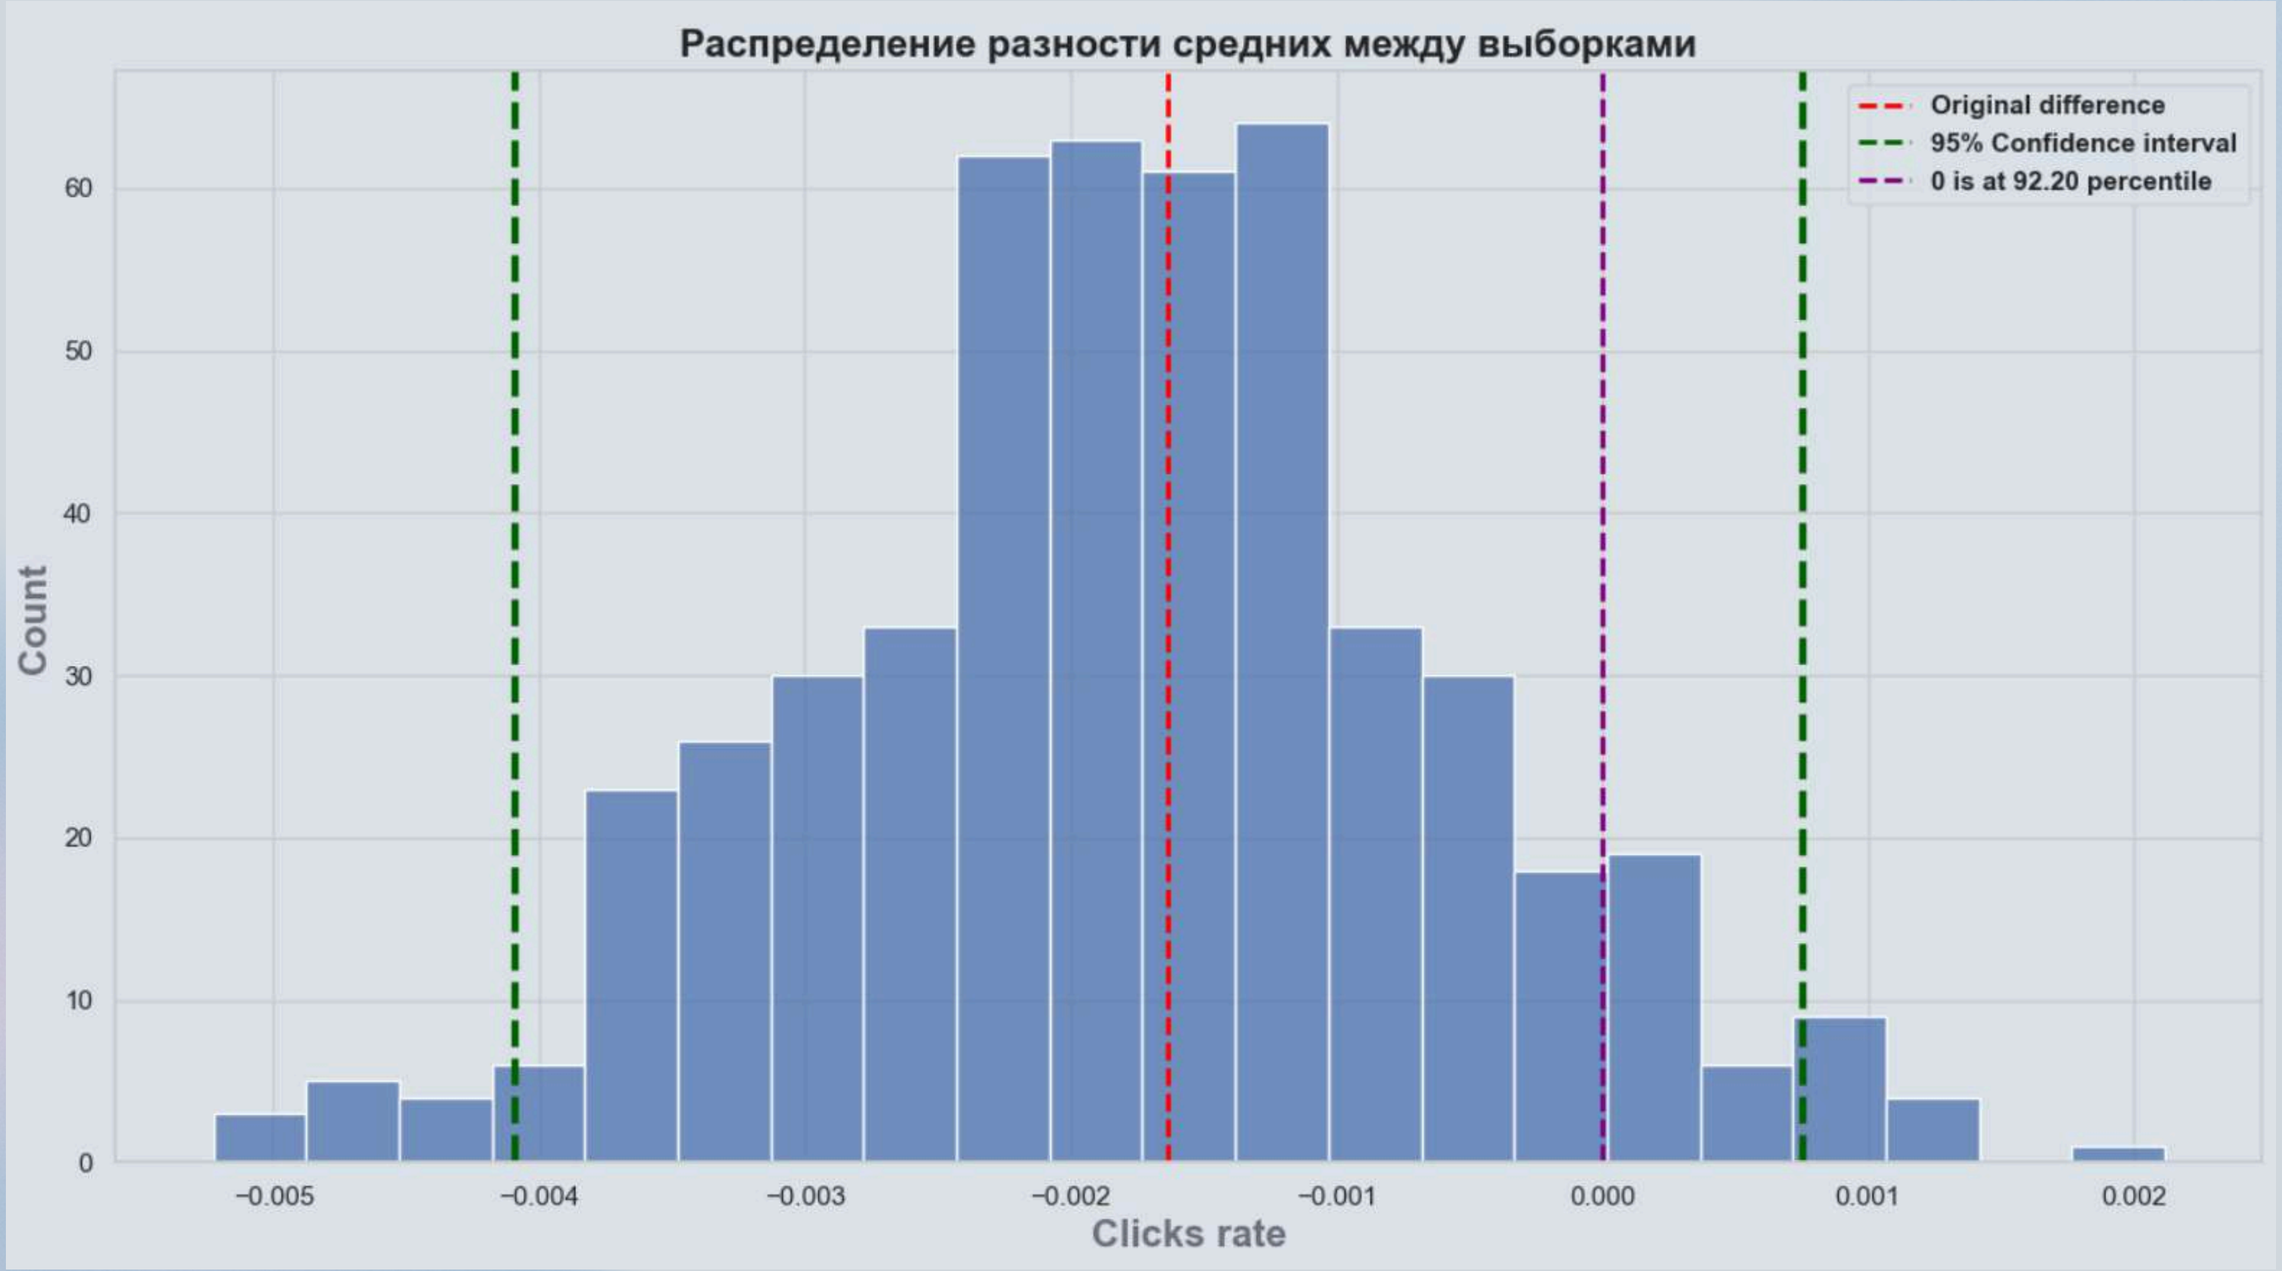
Распределение разности средних между выборками
Original difference
95% Confidence interval
0 is at 92.20 percentile
Count
0
10
20
30
40
50
60
−0.005
−0.004
−0.003
−0.002
−0.001
0.000
0.001
0.002
Clicks rate

Вывод

По результатам проведенного анализа не было зафиксировано статистически значимое различие в конверсиях контрольной и экспериментальной выборок.
К тому же, **>90%** значений разности конверсий, в полученном в результате bootstrap-анализа распределении, лежат на отрицательной части оси.

Z-тест для пропорций: p-value ≈ 0,19

ДИ распределения разности конвсерсий содержит 0...

И лежит по большей части на значениях < 0!

Таким образом, организации скорее **стоит отказаться от нового лэндинга страницы**, поскольку эффект хоть и не является значимым, но ближе к отрицательному.

Part 2

Diabetes: HbA1c

Контекст проблемы

- Управление гипергликемией у госпитализированных с диабетом пациентов оказывает существенное влияние на исход заболевания, как с точки зрения заболеваемости, так и смертности. Однако **не существует единых оценок качества** лечения диабета во время госпитализации, которые могли бы служить отправной точкой для изменений.

- **HbA1c** - показатель крови, отражающий среднее содержание сахара в крови за длительный период (от трёх до четырёх месяцев), в отличие от измерения **<u>глюкозы</u>** крови, которое дает представление об уровне глюкозы крови только на момент исследования.

Цель исследования

- Определить, как проведение анализа на HbA1c, его результаты и другие сопутствующие факторы влияют на исход лечения пациентов, больных диабетом.

EDA

- Раса, возраст, пол
- id посещения и пациента
- Кол-во посещений за последний год
- Принимаемые лекарства
- Результаты HbA1C теста
- Изменение плана лечения
- Кол-во анализов
- Тип выписки и поступления
- Кол-во дней в больнице
- Возвращение пациента после лечения

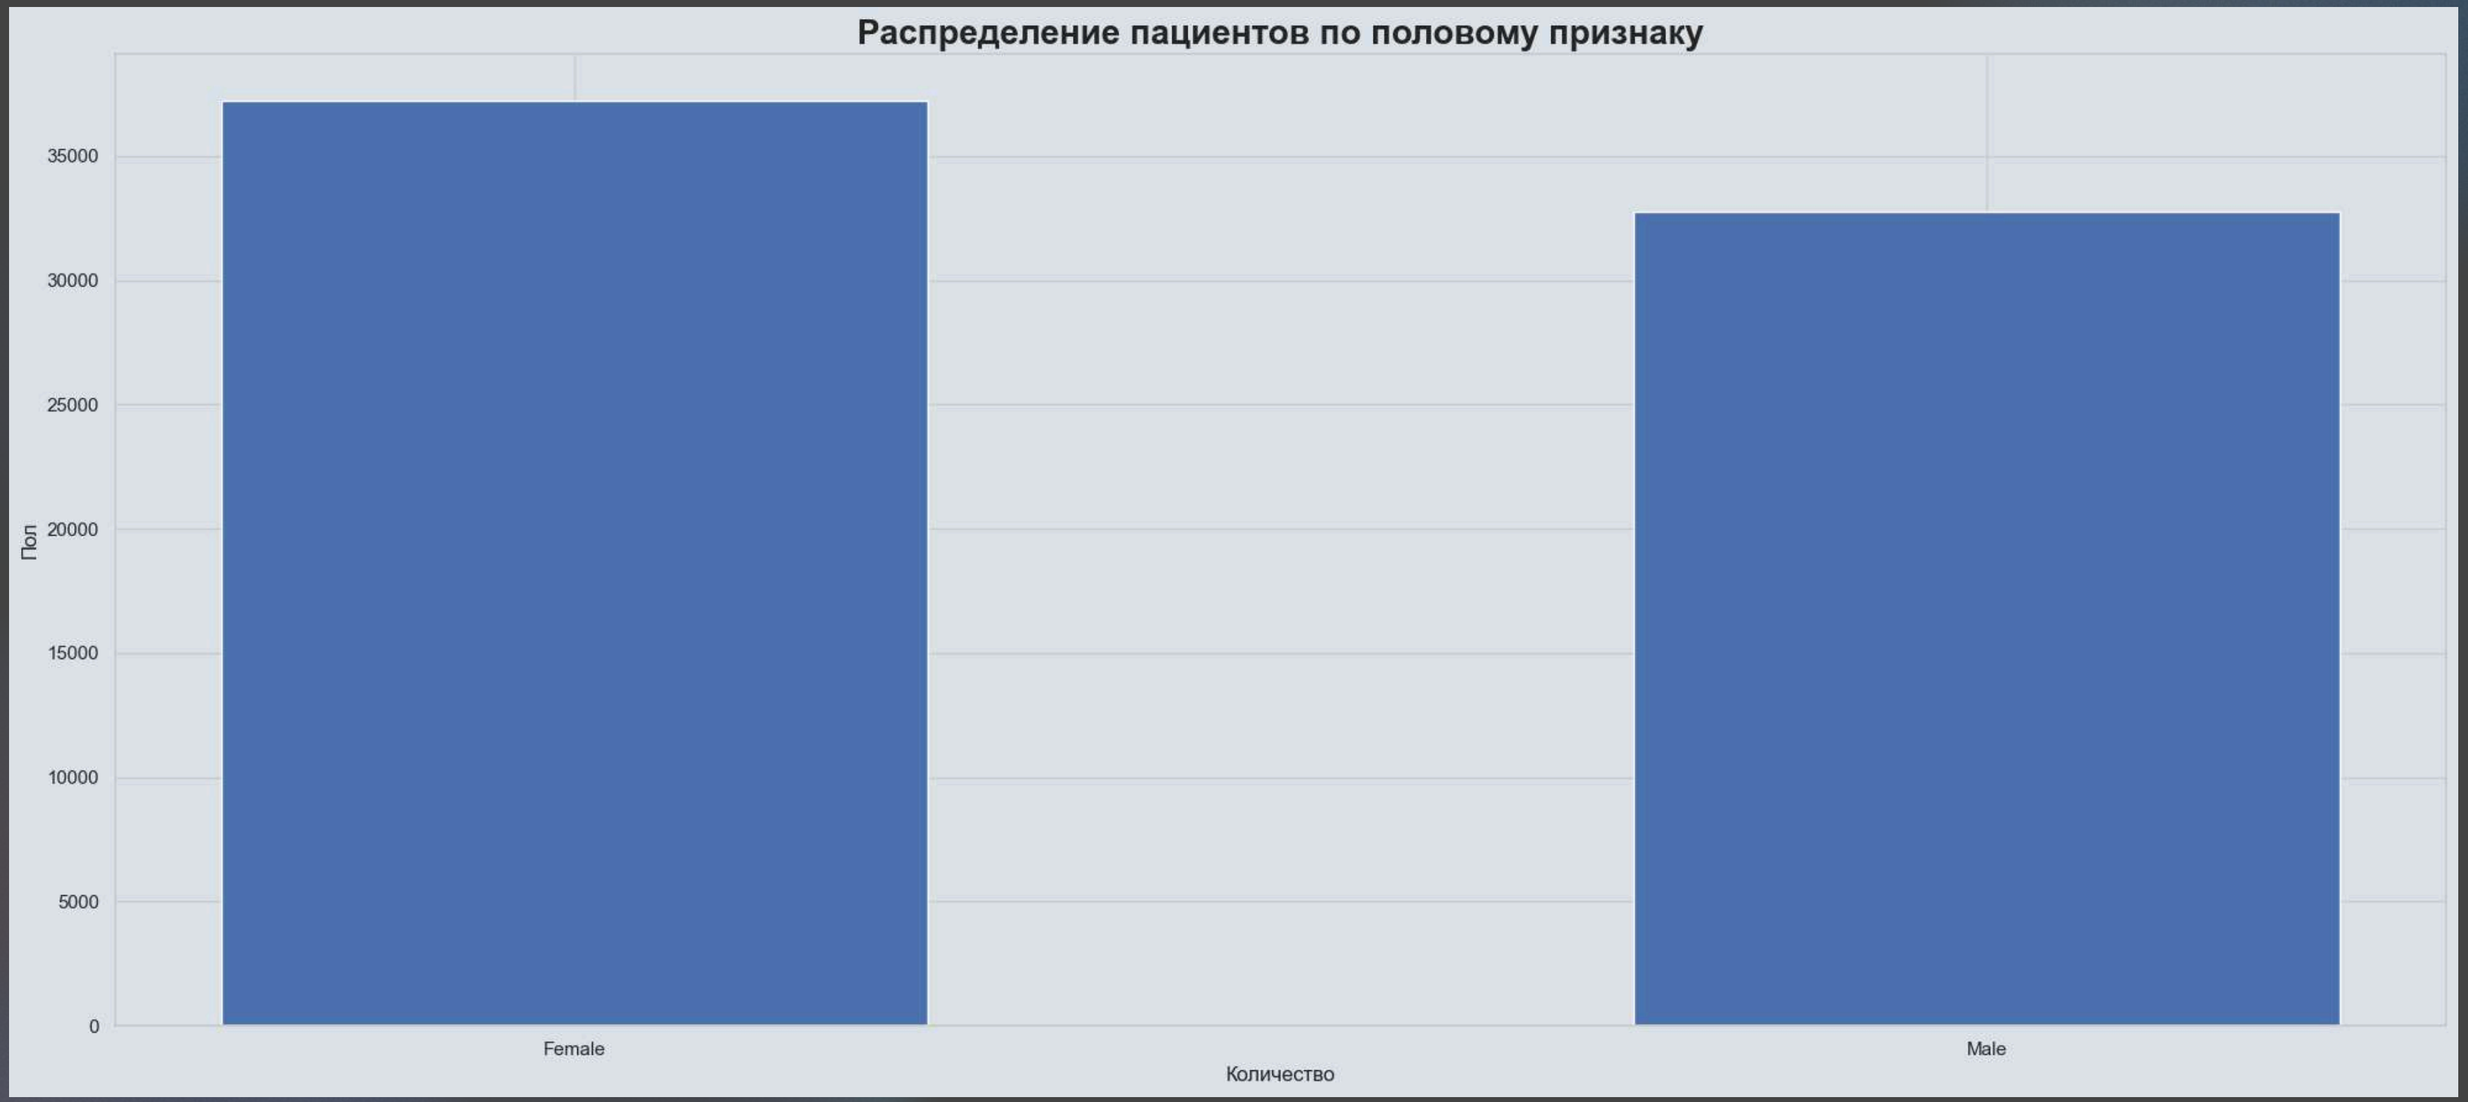
Распределение пациентов по половому признаку
35000
30000
25000
20000
15000
10000
5000
0
Пол
Female
Male
Количество

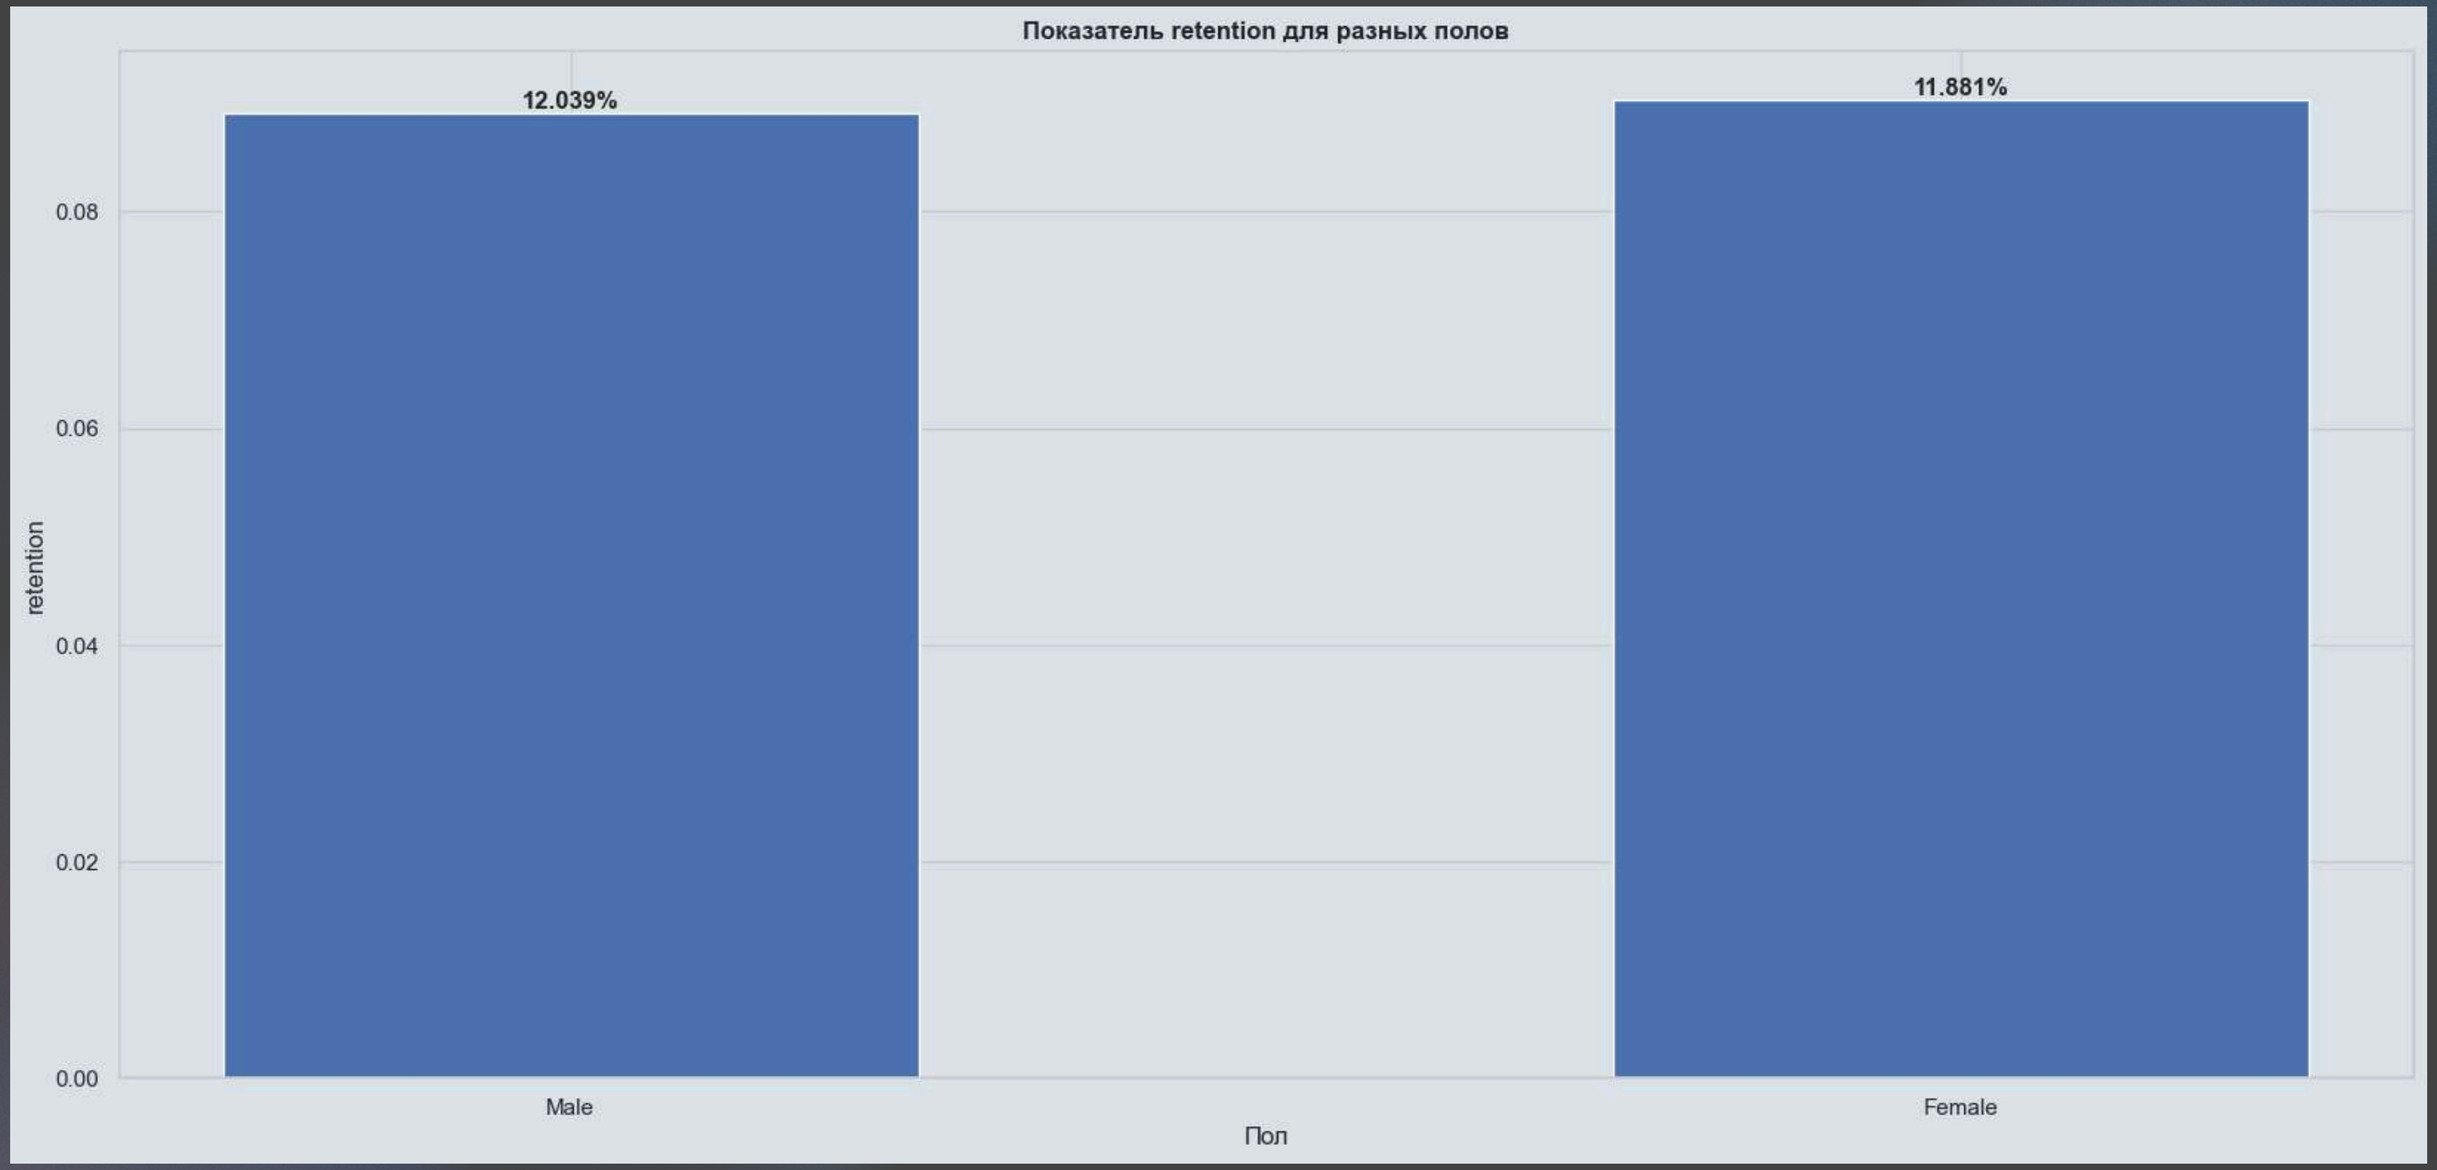
Показатель retention для разных полов
12.039%
11.881%
0.08
0.06
0.04
0.02
0.00
retention
Male
Female
Пол

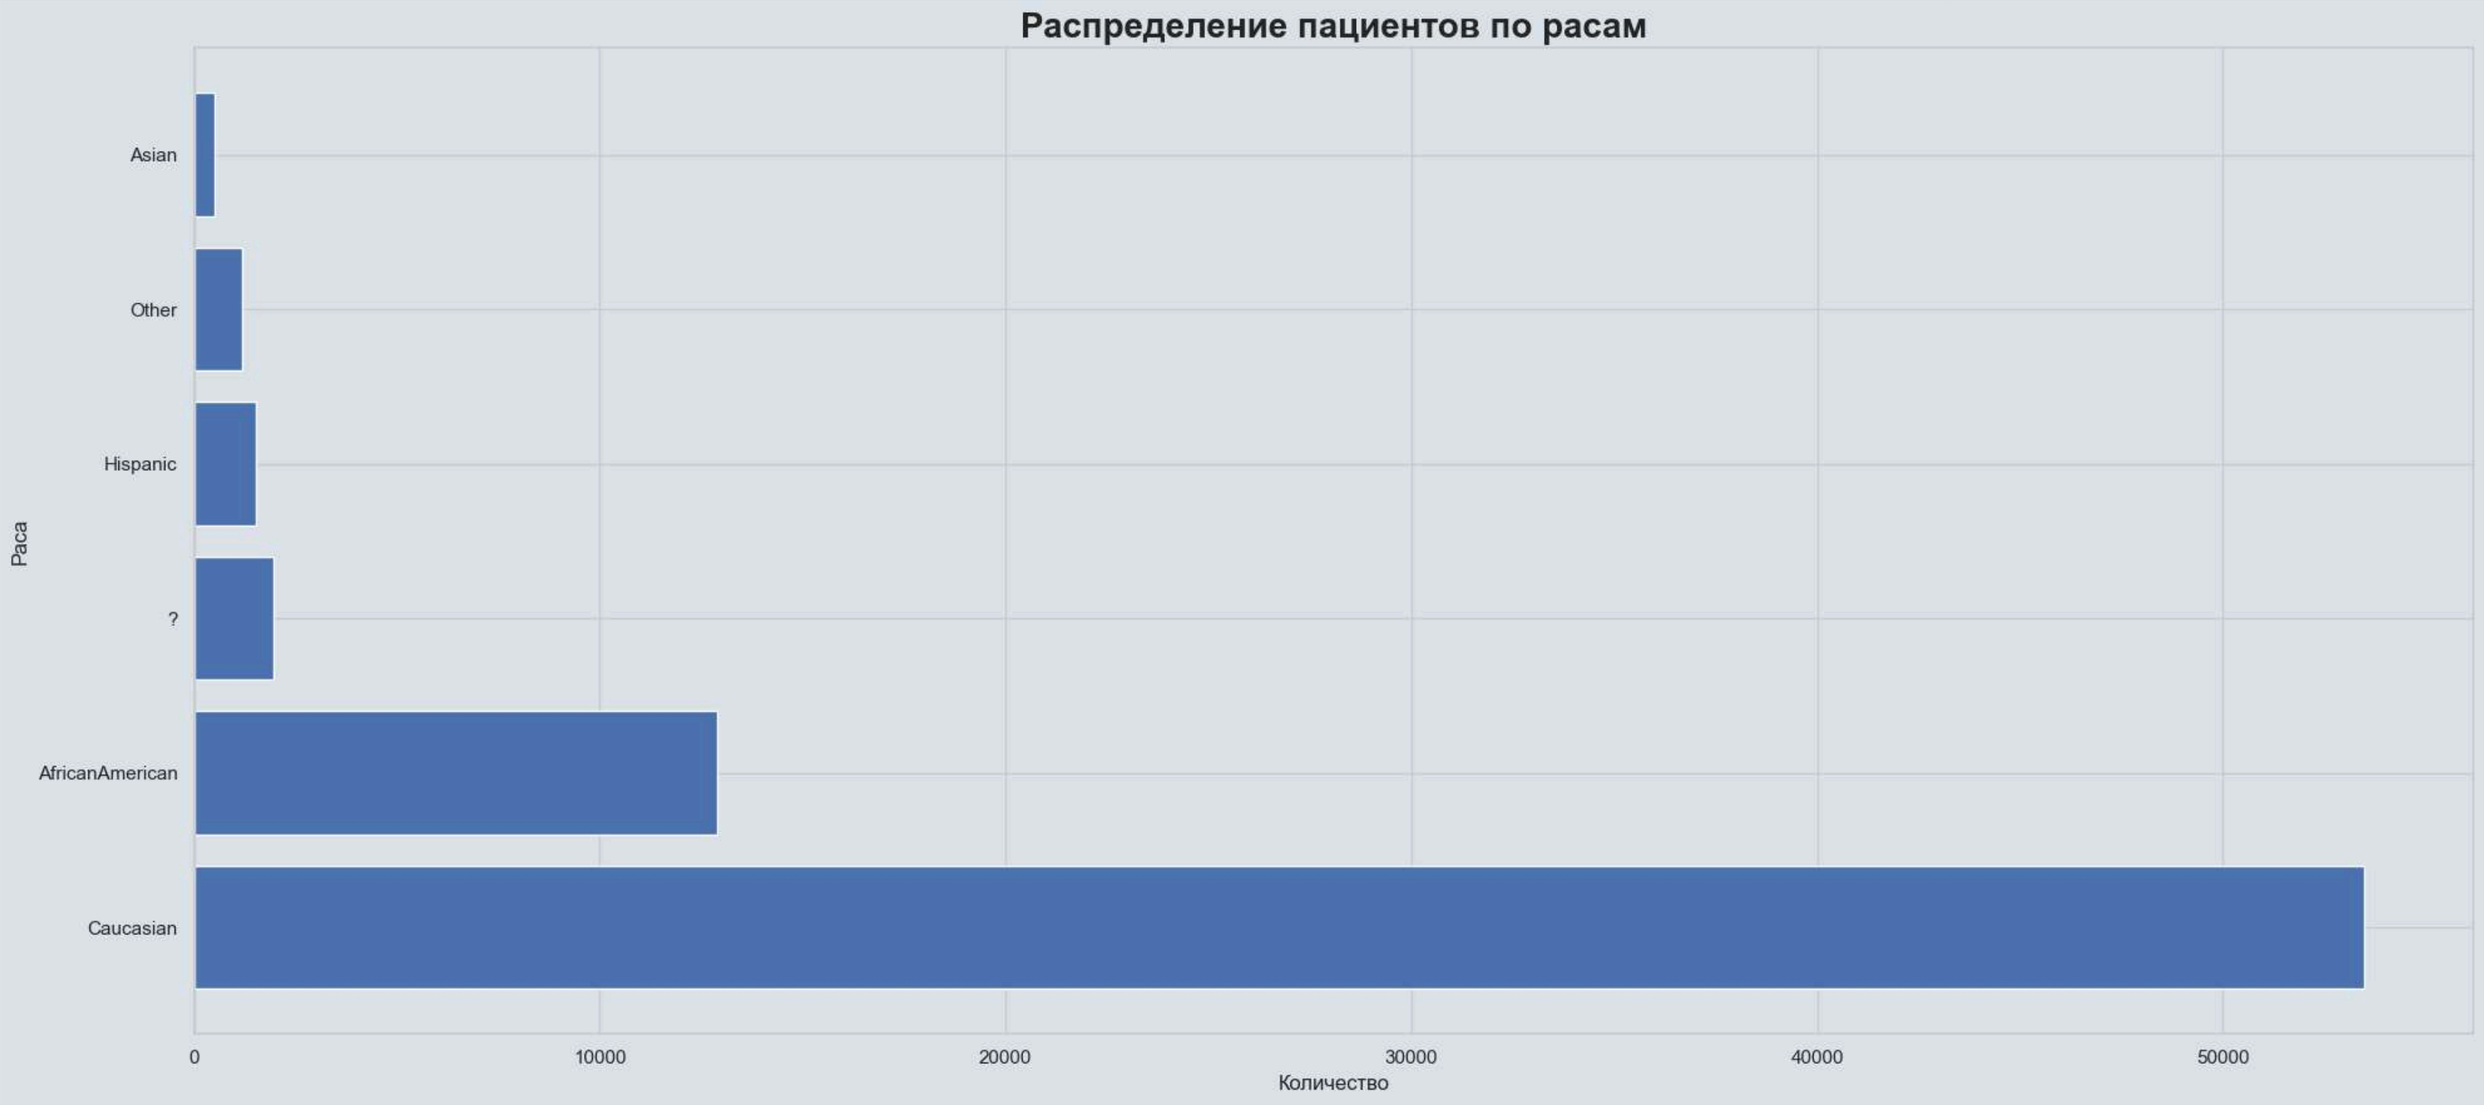
Распределение пациентов по расам
Asian
Other
Hispanic
?
AfricanAmerican
Caucasian
Раса
0
10000
20000
30000
40000
50000
Количество

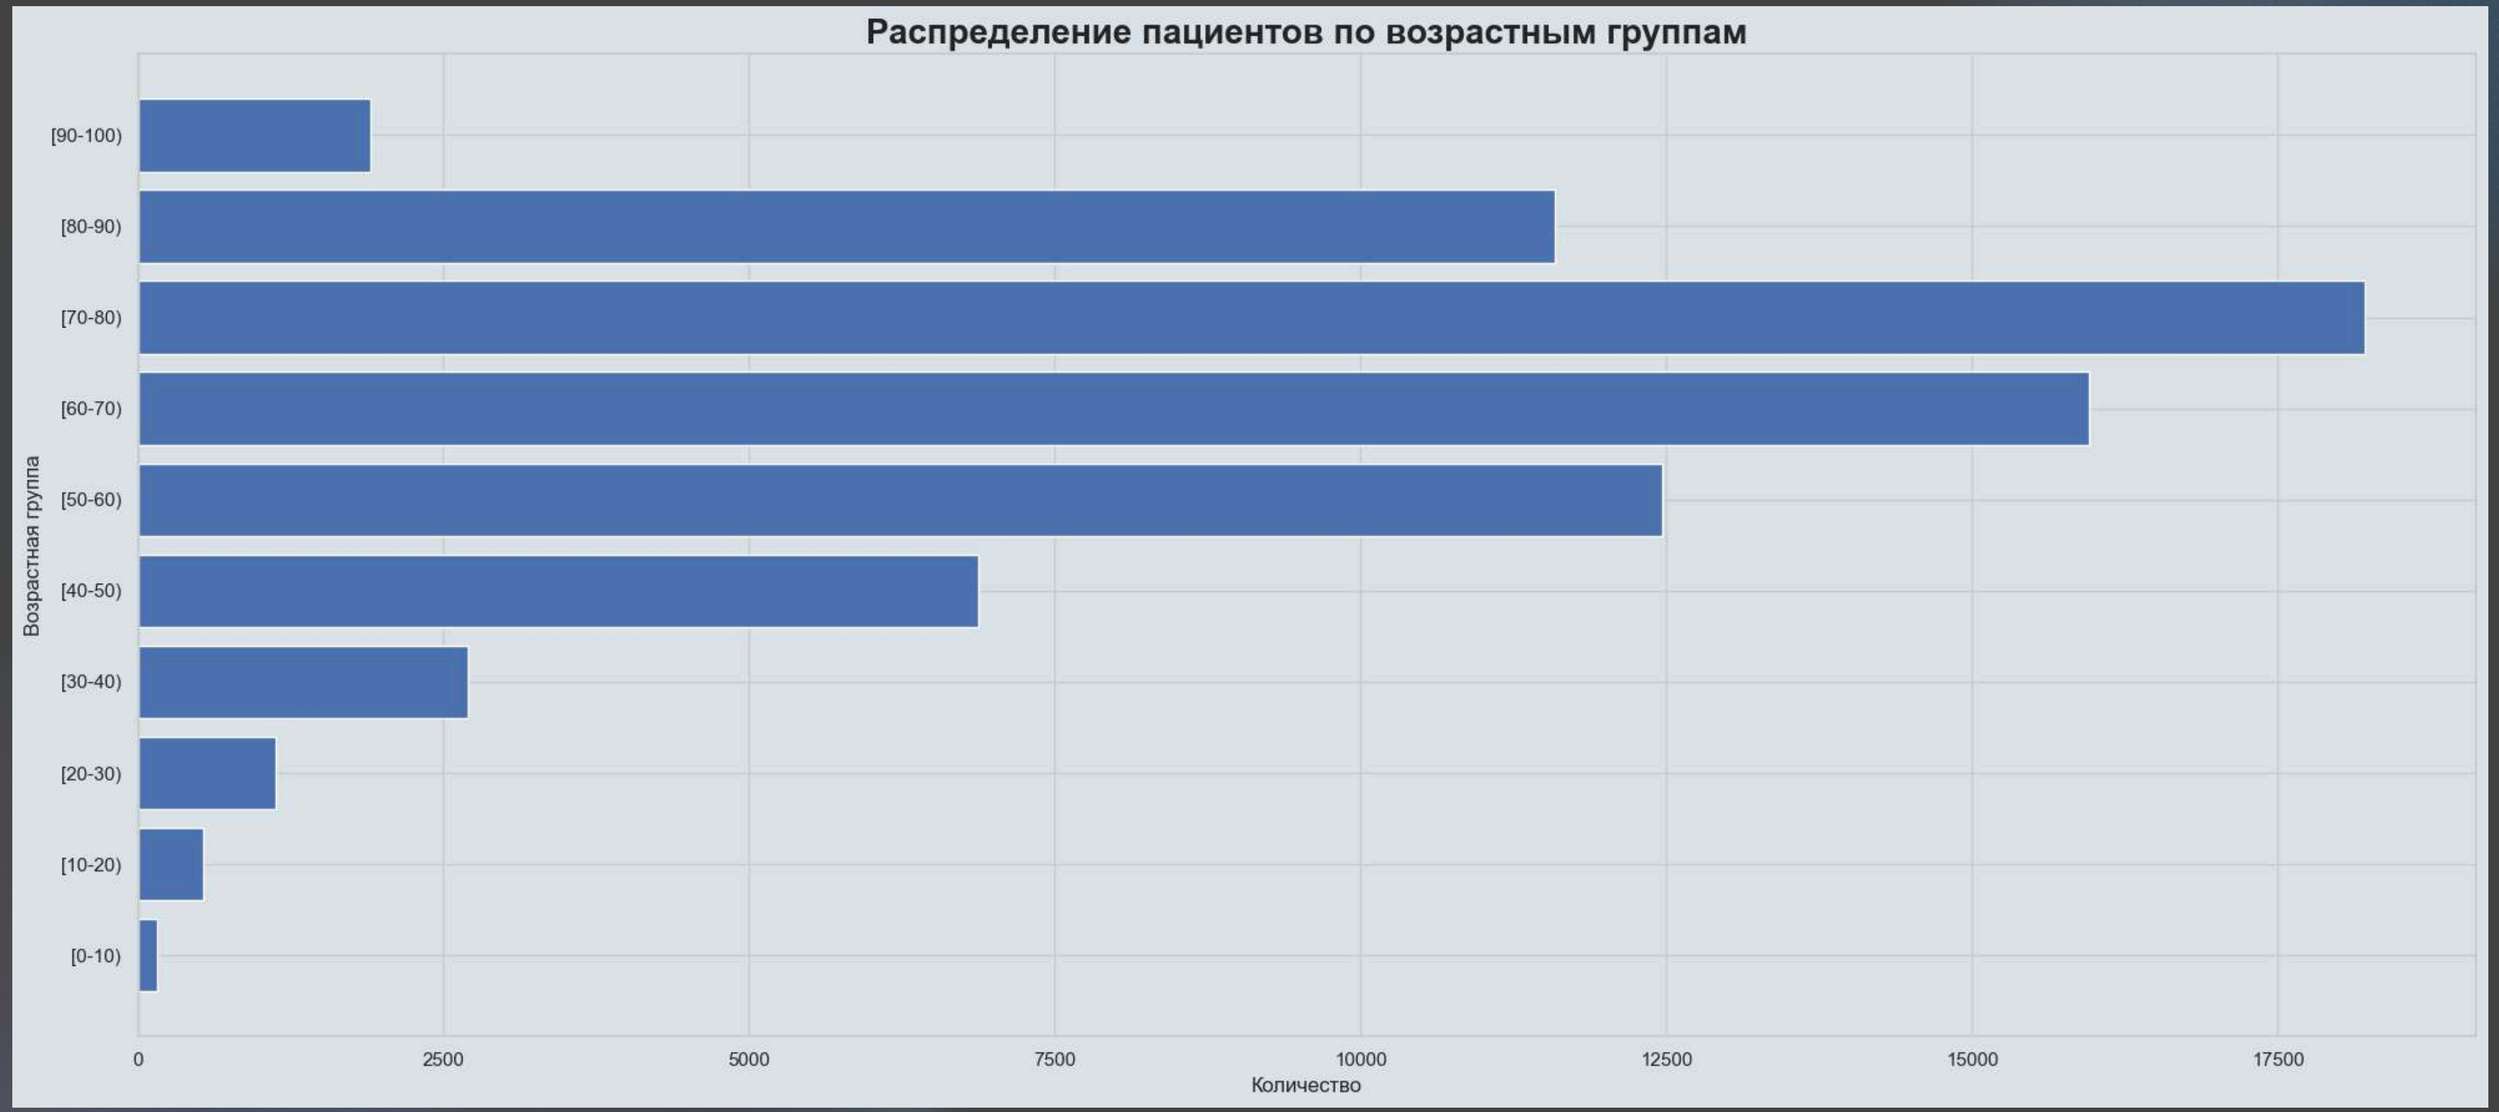
Распределение пациентов по возрастным группам
Возрастная группа
[90-100)
[80-90)
[70-80)
[60-70)
[50-60)
[40-50)
[30-40)
[20-30)
[10-20)
[0-10)
0
2500
5000
7500
10000
12500
15000
17500
Количество

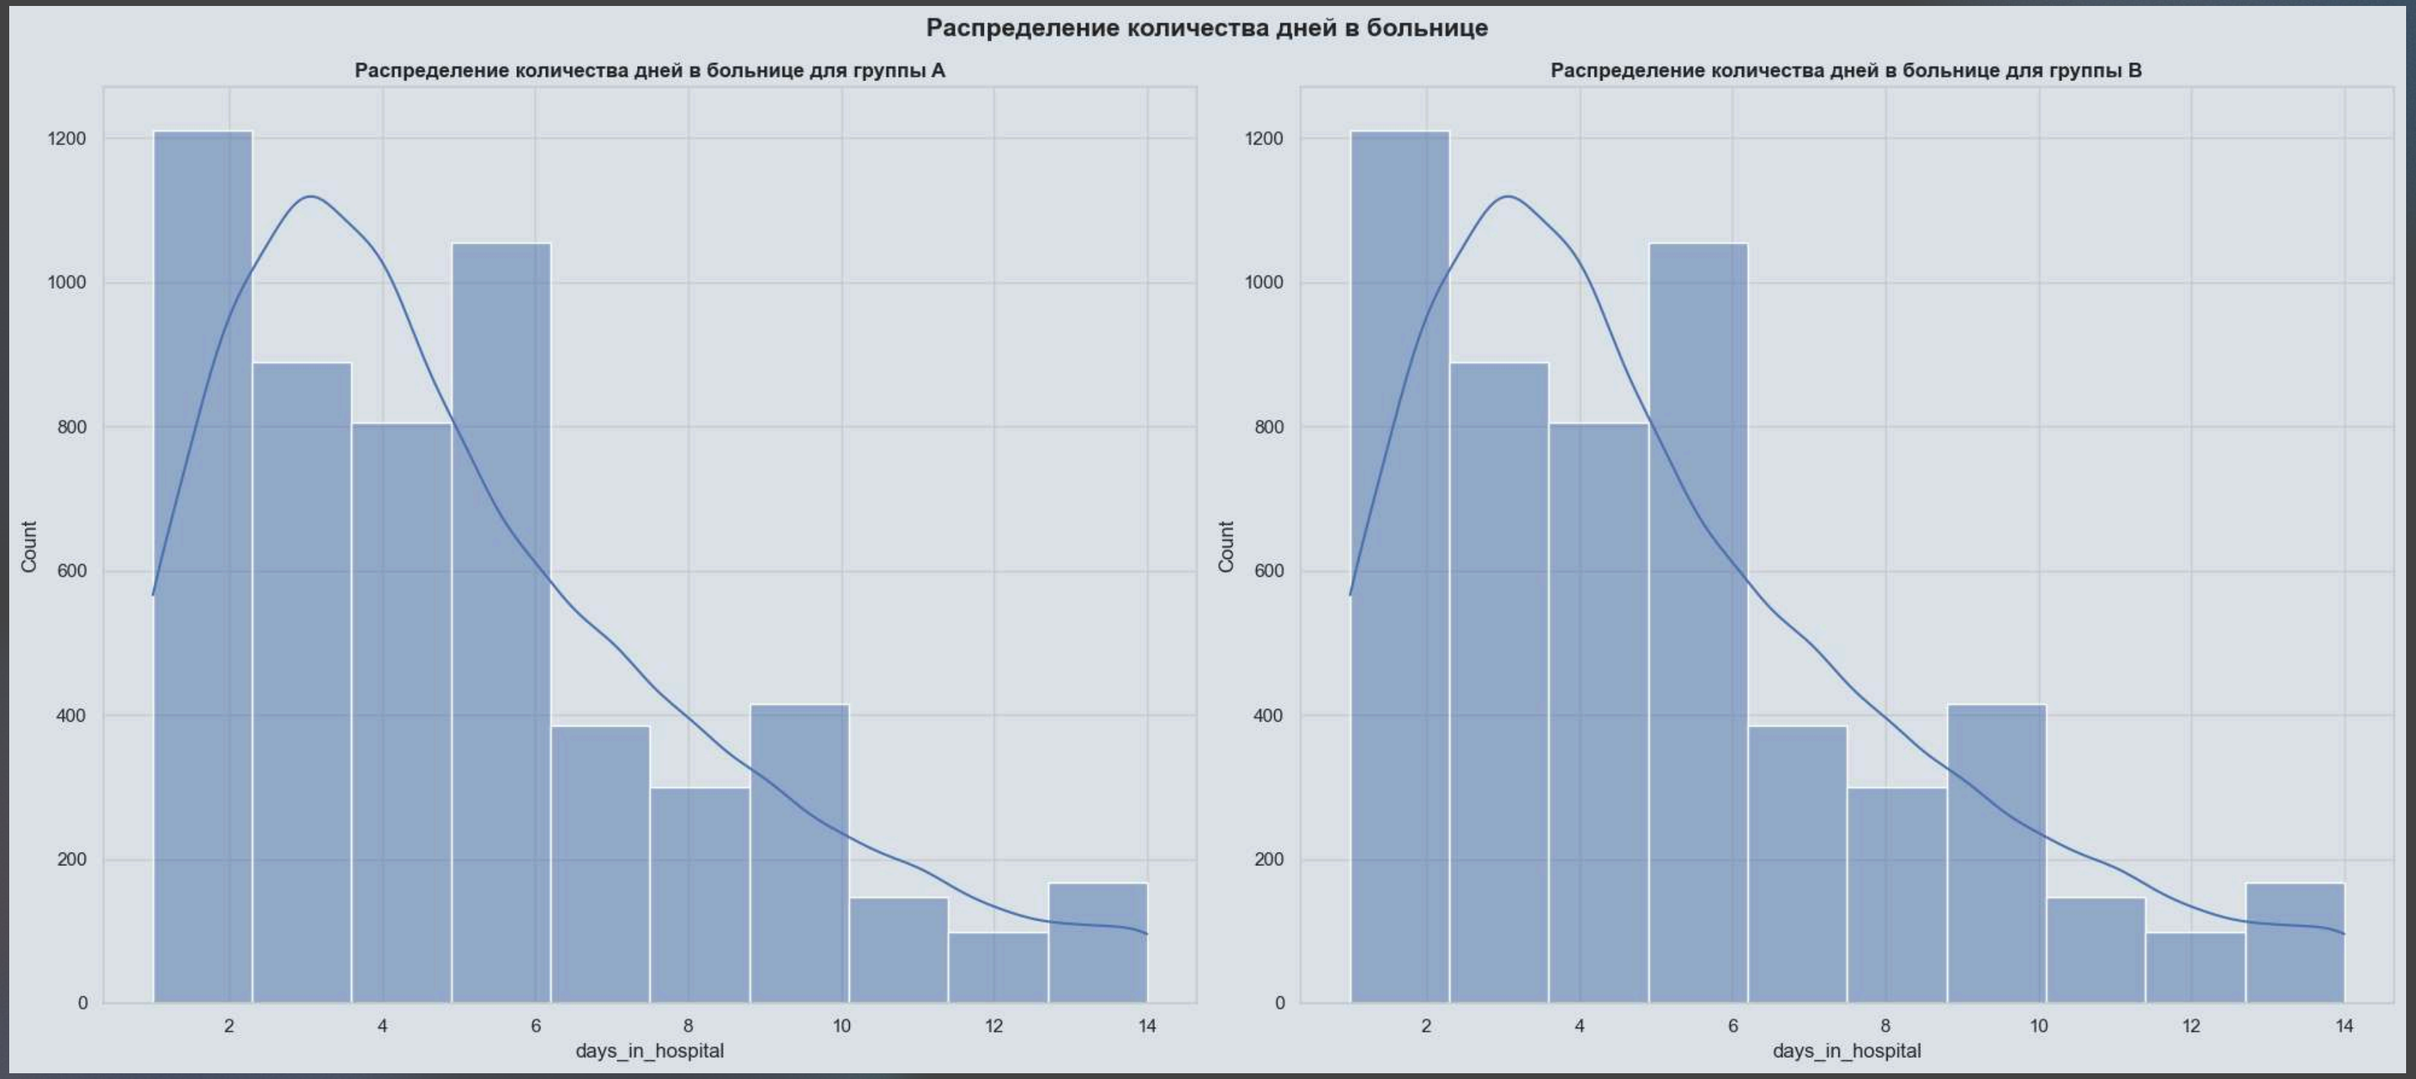
Распределение количества дней в больнице
Распределение количества дней в больнице для группы A
Распределение количества дней в больнице для группы B
Count
days_in_hospital
0
200
400
600
800
1000
1200
2
4
6
8
10
12
14

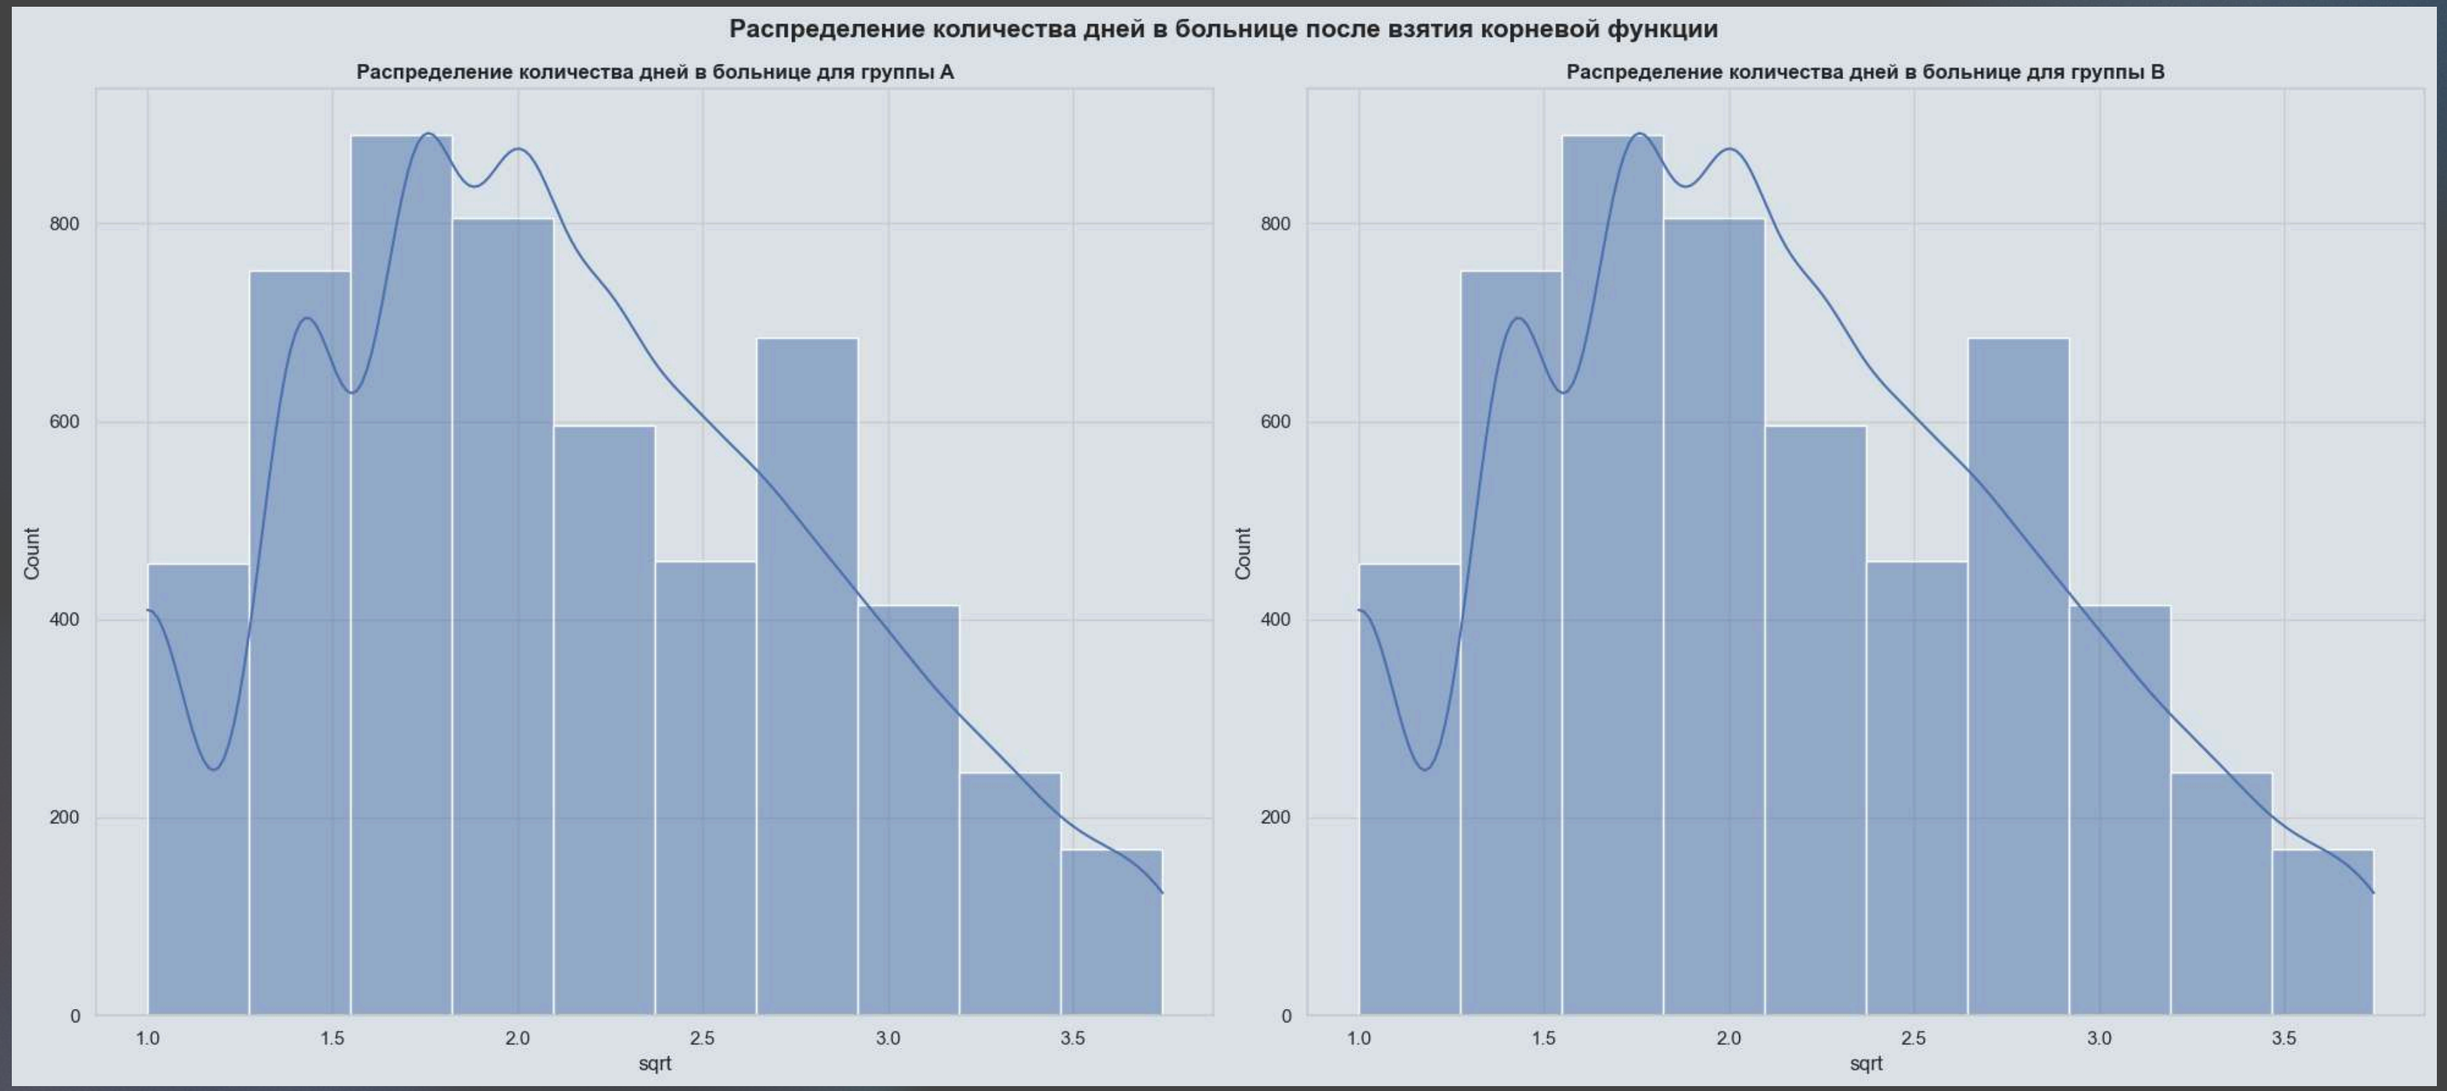
Распределение количества дней в больнице после взятия корневой функции
Распределение количества дней в больнице для группы A
Распределение количества дней в больнице для группы B
Count
sqrt
0
200
400
600
800
1.0
1.5
2.0
2.5
3.0
3.5

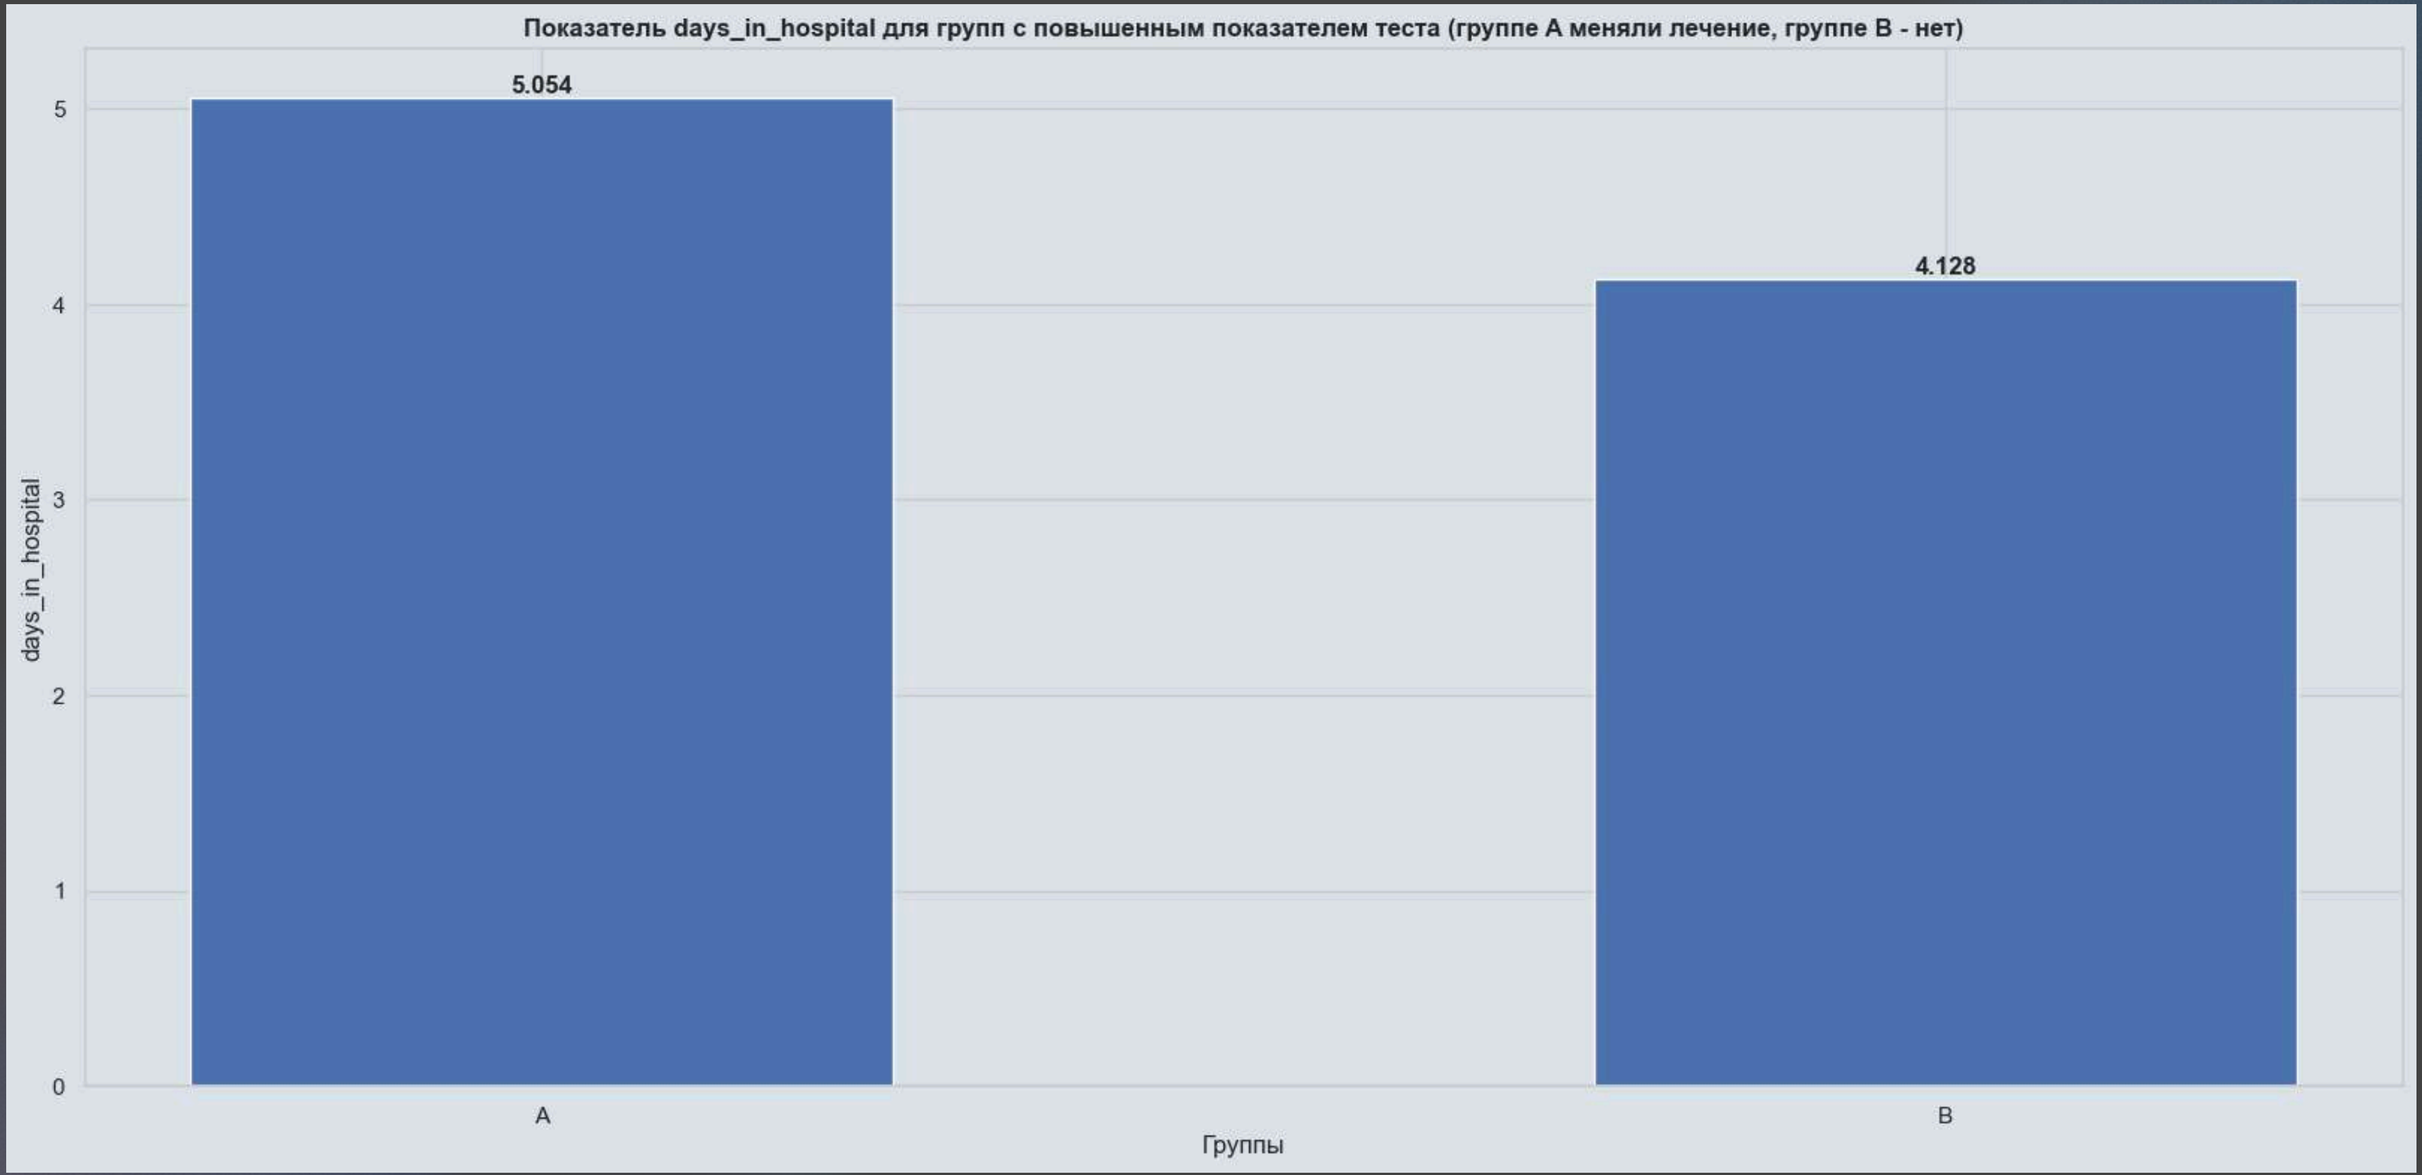
Показатель days_in_hospital для групп с повышенным показателем теста (группе A меняли лечение, группе B - нет)
5.054
4.128
days_in_hospital
0
1
2
3
4
5
A
B
Группы

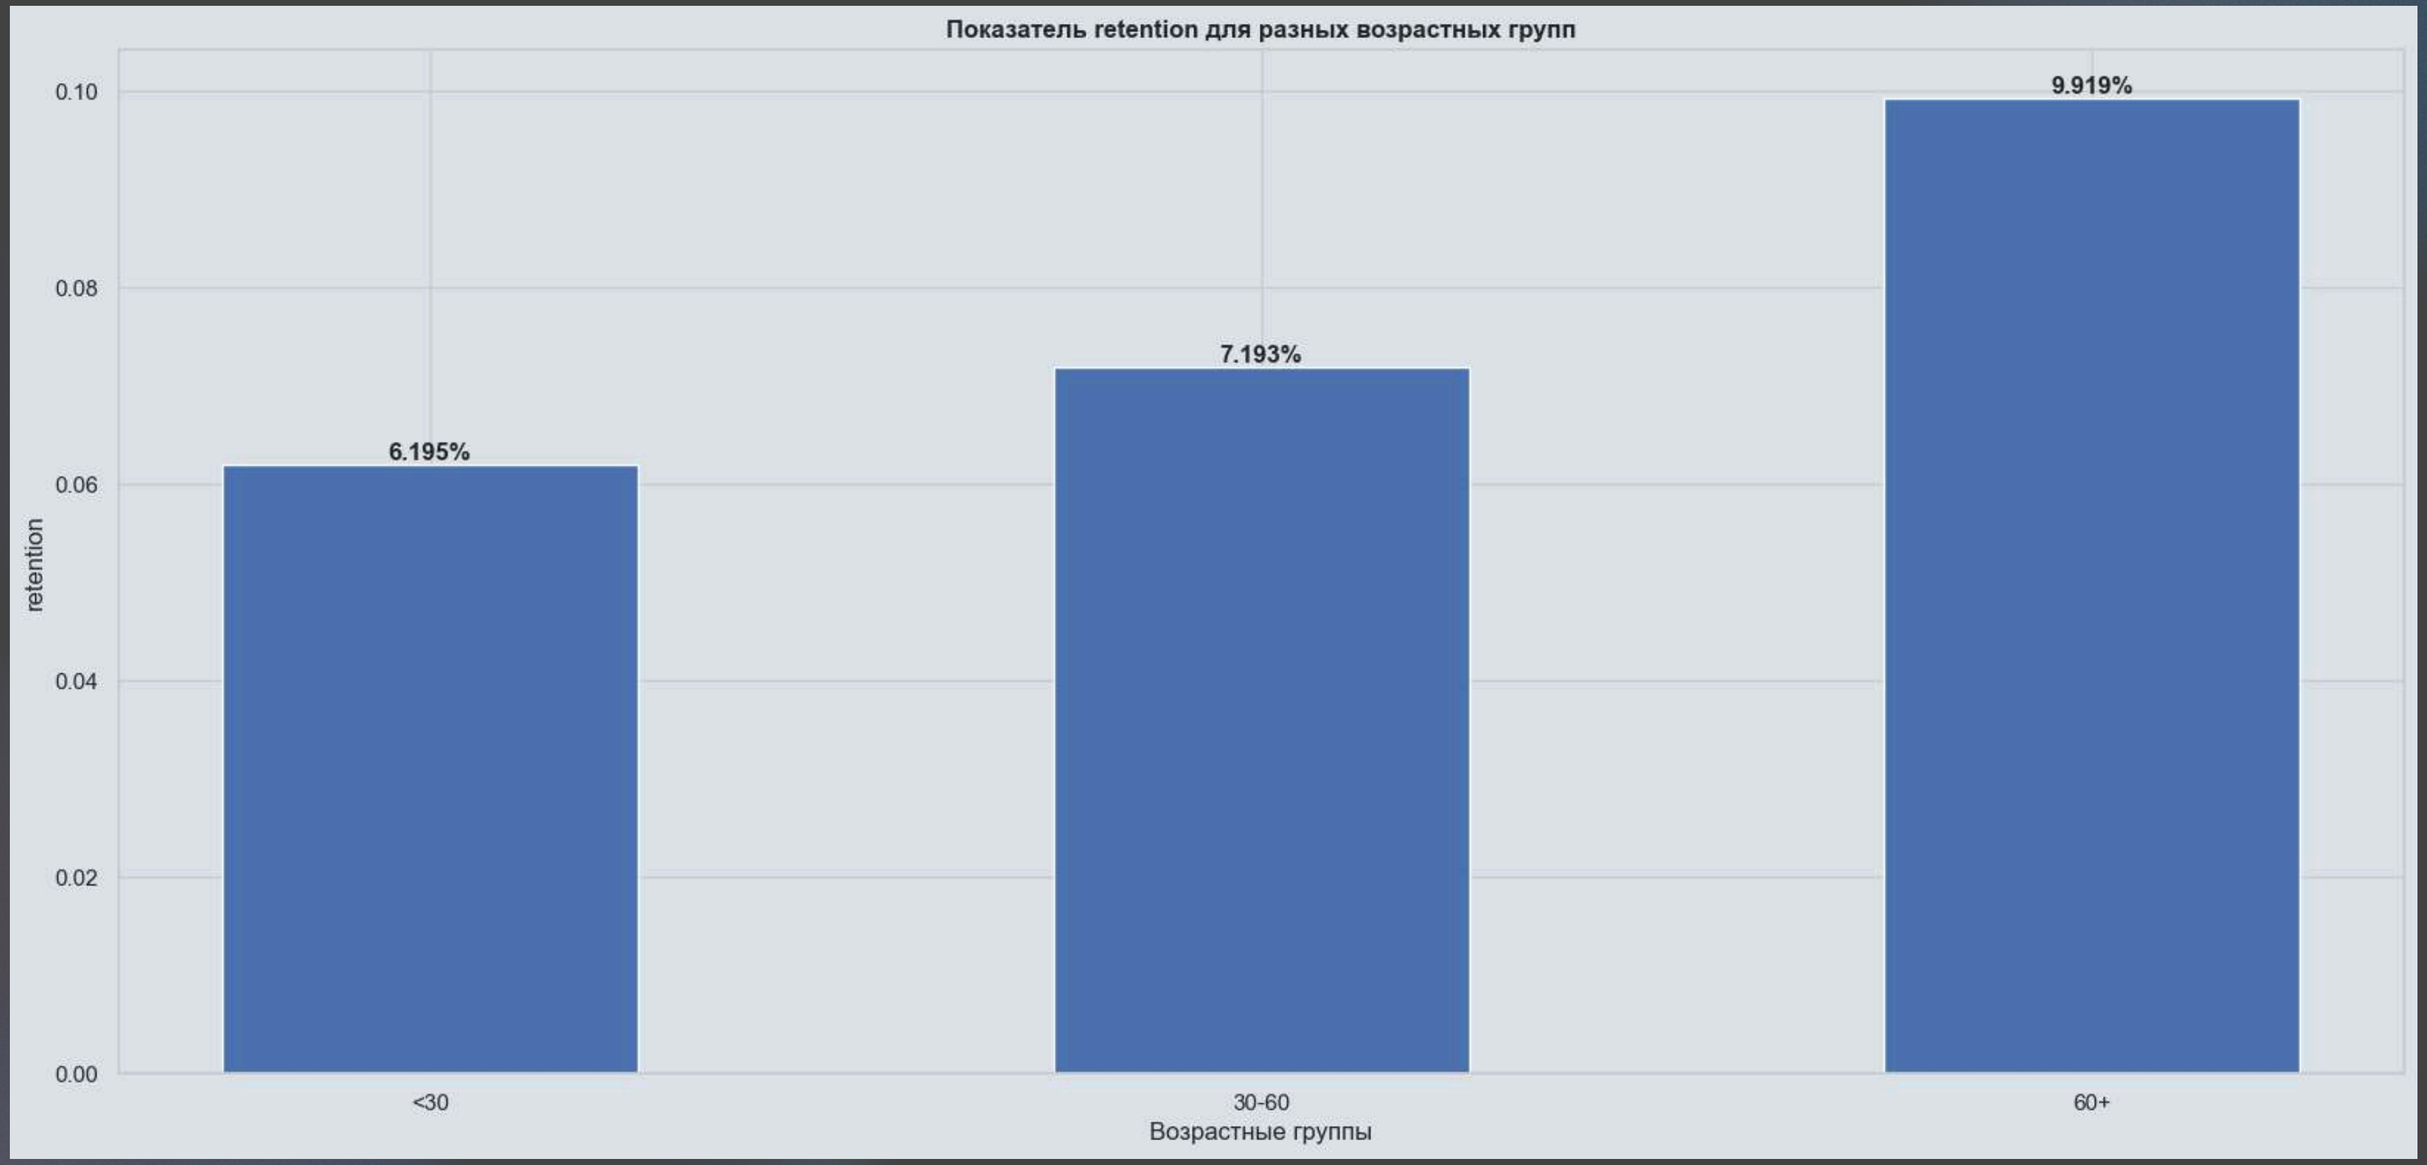
Показатель retention для разных возрастных групп
0.10
0.08
0.06
0.04
0.02
0.00
retention
6.195%
7.193%
9.919%
<30
30-60
60+
Возрастные группы

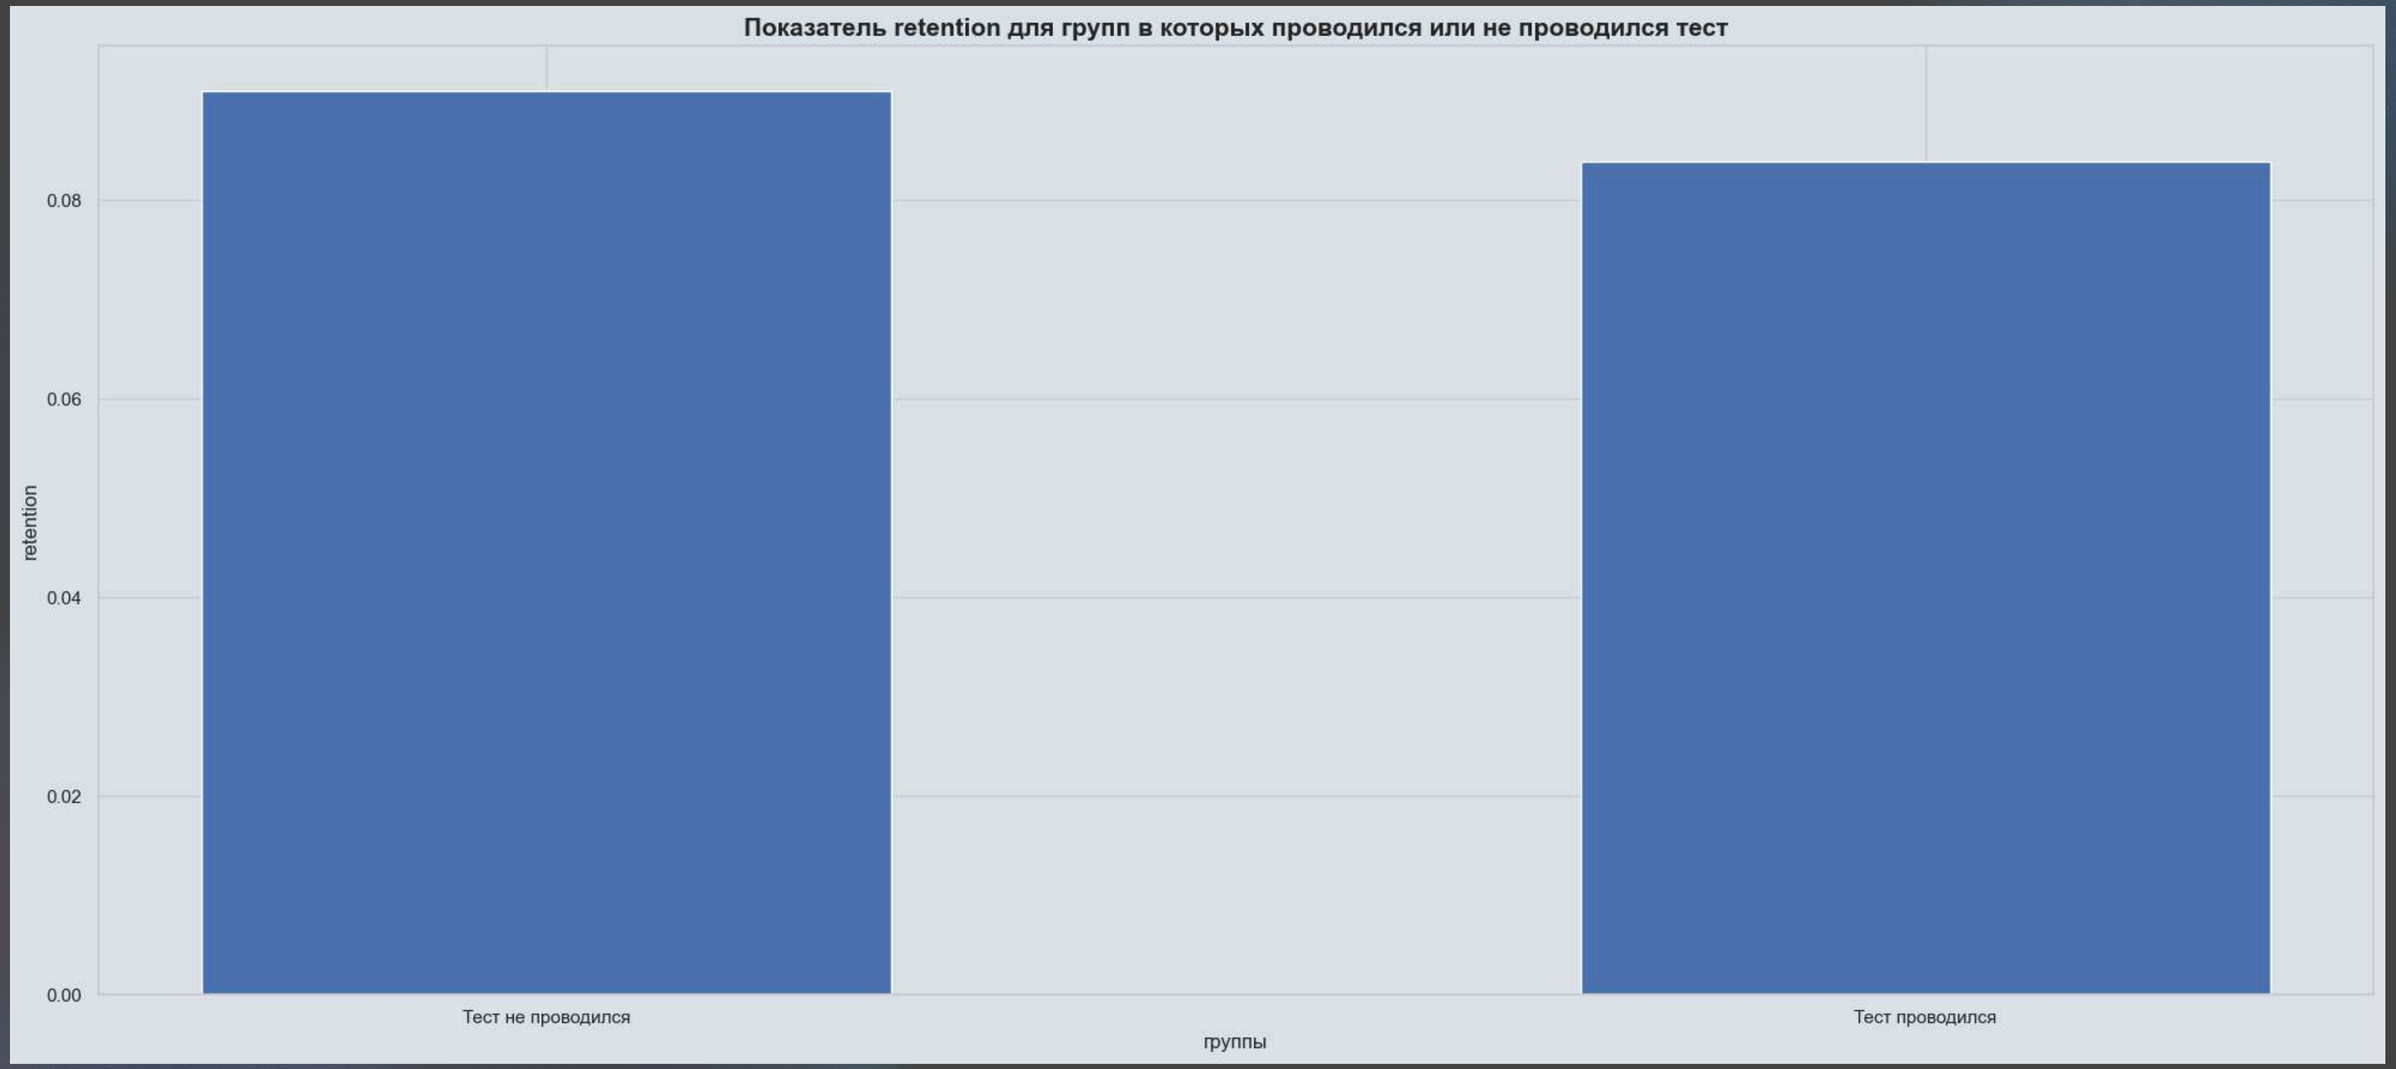
Показатель retention для групп в которых проводился или не проводился тест
retention
0.00
0.02
0.04
0.06
0.08
Тест не проводился
Тест проводился
группы

Hypothesis 1

H0 Смена лечения для людей с результатом HbA1C теста выше нормы не влияет на среднее количество дней, проведённых ими в больнице.

H1 Смена лечения для людей с результатом HbA1C теста выше нормы статисчески значимо и влияет на среднее количество дней, проведённых в больнице.

Для проверки гипотезы будем использовать тест Манна-Уитни, так как выборки не равные по размеру, дисперсии негомогенные и распределение выборок далеко от нормального. Возьмем уровень значимости α = 0.01

Hypothesis 1 Result

```
Статистика теста Левена для sqrt-преобразованных данных
Статистика: 6.888479043928797
p-value: 0.008689797546963784
Вывод: Дисперсии негомогенные так как p_val < 0.01
```

```
Статистика теста Манна-Уитни
Статистика: 11801136.0
p-value: 7.207337376079659e-53
```

INTERPRETATION

p_value < α. Значит мы отклоняем нулевую гипотезу и принимаем альтернативную, а именно, что
смена лечения для людей с повышенном тестом статистически значима

Hypothesis 2

H0 Пациенты, выписанные домой, в среднем лечились более интенсивно, чем те, кто выписан не был.

H1 Пациенты, выписанные домой, в среднем лечились более интенсивно, чем те, кто выписан не был.

Для проверки гипотезы мы воспользовались методом bootstrap, т.к. данные не были распределены нормально.

Hypothesis 2 Result

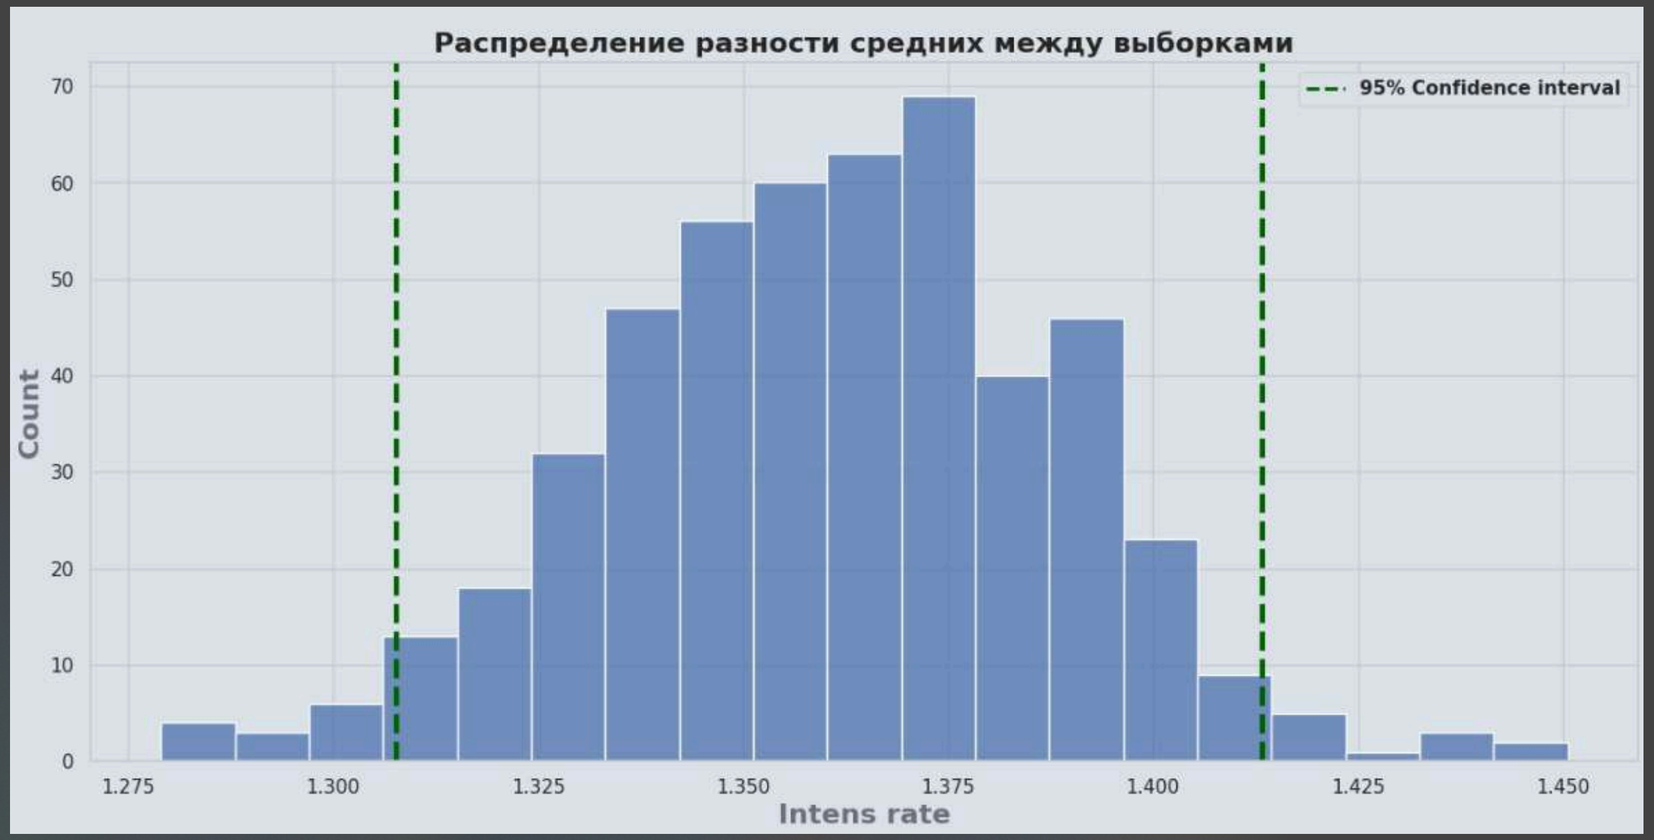

INTERPRETATION

CI не покрывает 0, следовательно эффект статистически значим, значит отклоняем H0

Hypothesis 3

H0

Возраст (принадлежность к возрастной группе) не оказывает влияние на частоту возвращения в течении 30 дней

H1

В зависимости от возраста (принадлежности к определенной возрастной группе) человек реже или чаще возвращается в больницу в течении 30 дней

Для проверки гипотезы будем использовать тест Хи-квадрат, так как у нас три группы не равные по размеру, и мы ищем завимость от категорионального признака. Возьмем уровень значимости α = 0.01

Hypothesis 3 Result

```
Результаты теста хи-квадрат
Chi2 = 152.732383284812
p-value = 6.832574341909008e-34
```

INTERPRETATION

p_value < α. Значит мы отклоняем нулевую гипотезу и принимаем альтернативную, а именно, что возраст влияет на факт возвращение в больницу

Hypothesis 3 Result

```
Статистика теста Манна-Уитни для групп <30, 30-60
Статистика: 19966904.0
p-value: 0.11263776713105786
```

```
Статистика теста Манна-Уитни для групп <30, >60
Статистика: 492389029.0
p-value: 4.889836200938829e-31
```

```
Статистика теста Манна-Уитни для групп 30-60, >60
Статистика: 40290112.0
p-value: 1.6885343246091614e-07
```

INTERPRETATION

Как мы видим у нас есть не стат значимые различия между возрастными группами <30 и 30-60, и стат значимые различия группы >60 с остальными, что позволяет сделать вывод о том, что при возрасте > 60 лет, люди чаще возвращаются в больницу после лечения

Hypothesis 4

H0 Факт проведения теста на HbA1c не влияет на то, попадет ли пациент в больницу в течение 30 дней после выписки.

H1 Пациенты, у которых проводился тест , в среднем реже попадали в больницу в течение 30 дней после выписки, чем те, у которых тест не проводился.

Для проверки гипотезы будем использовать тест z-test для пропорций, так как у нас бинарная метрика и большое кол-во данных. Возьмем уровень значимости α = 0.01

Hypothesis 4 Result

```
Результаты z-теста пропорций
Z-stat = 2.5397503359572 19
p-value = 0.0110931625369550 34
```

INTERPRETATION

p_value > α = 0,01. Значит мы принимаем нулевую гипотезу, а именно, что факт проведения теста на HbA1c скорее не влияет на то, попадет ли пациент в больницу в течение 30 дней после выписки.

Delving into the hypotheses

H0

После учёта возраста пациента, тяжести состояния и типа поступления, факт проведения HbA1C-теста не оказывает статистически значимого влияния на вероятность ранней повторной госпитализации.

H1

После учёта возраста пациента, тяжести состояния и типа поступления, проведение HbA1C-теста является независимым фактором, статистически значимо влияющим на вероятность ранней повторной госпитализации.

Для проверки гипотезы о независимом влиянии проведения HbA1C-теста на риск ранней повторной госпитализации с учётом возраста, тяжести состояния и типа поступления была построена модель логистической регрессии.

Logistic Regression

Для того, чтобы отразить стадию заболевания , мы создали новый признак – severity, определяемый препаратами, которые принимал пациент

Вывод:
p_value = 0.032 > 0.01. Поэтому мы принимаем нулевую гипотезу и утверждаем, что проведение **HbA1C-теста** не оказывает статистически значимого влияния на вероятность ранней повторной госпитализации.

Результаты модели

name	coef	std err	p_value
test_done	-0.0761	0.036	0.032
60y or more	0.3499	0.031	0.001
less than 30y	-0.1789	0.101	0.077
severity	0.0905	0.011	0.001
admission_urgent	0.0594	0.029	0.041

Risk factor assessment model

PROBLEM

Одной из главных задач нашего анализа является выявление признака повторной госпитализации

SOLUTION

Построена логистическая регрессионная модель для выявления факторов, наиболее влияющих на риск **readmition**.

Model Results

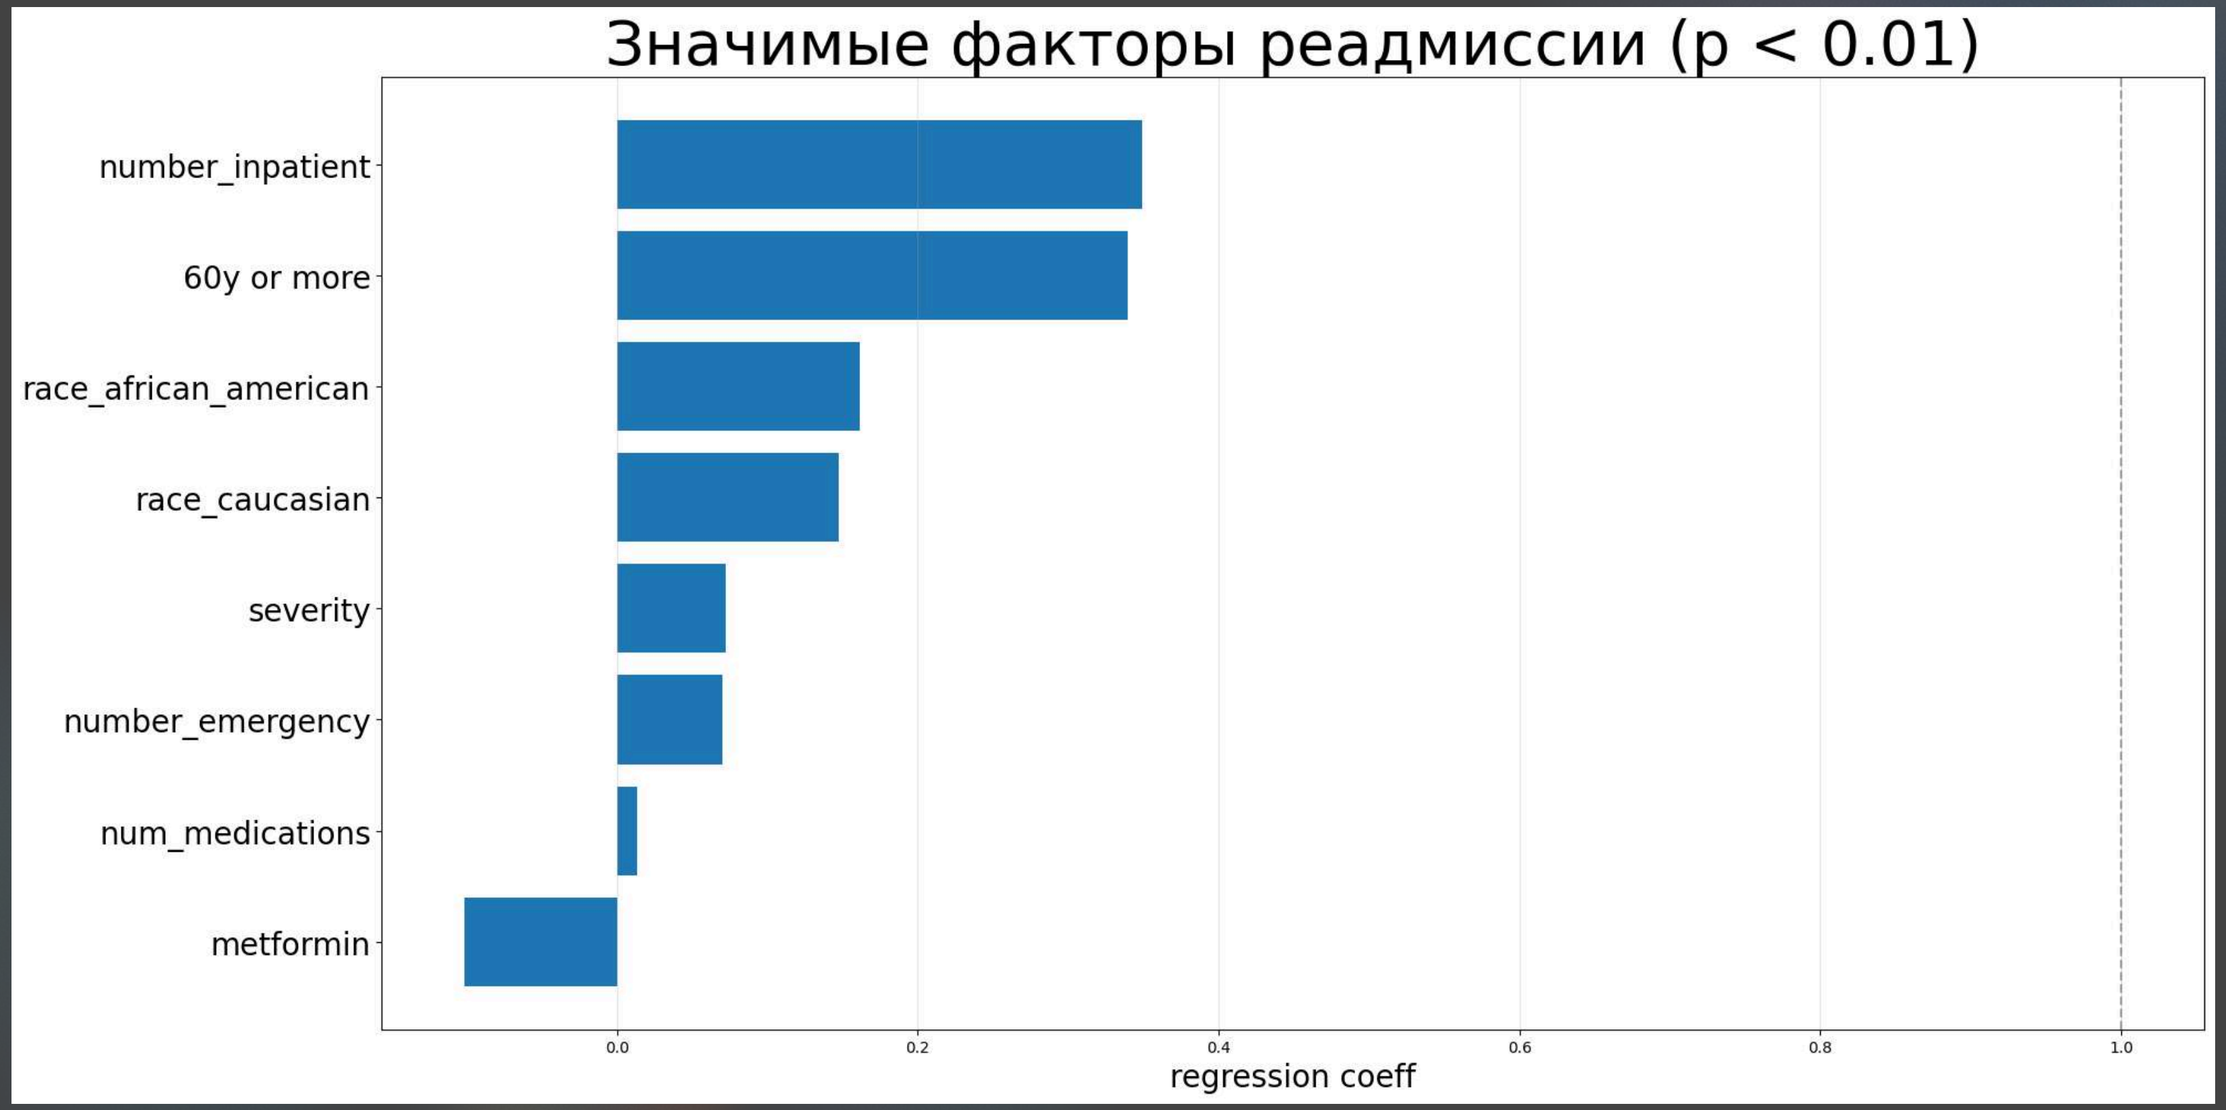

ML model

Результаты модели

	precision	recall	f1-score
0	0.9222	0.5925	0.7215
1	0.1099	0.5018	0.1804
accuracy			0.5842
macro avg	0.5161	0.5472	0.4509
weighted avg	0.8482	0.5842	0.6722

Accuracy: 0.5842

EXPLANATION

Так как мы знаем, какие признаки сильнее всего влияют на риск повторной госпитализации, построим модель логистической регрессии для **предсказания** данного фактора

PROBLEM

Было ожидаемо, что будет большая ошибка. Это связано с тем, что модели сложно выявлять людей с повторной госпитализацией, тк выборки неравномерные (вернувшихся всего 10%). Также у них низкий recall

ML model problem solution

SOLUTION

Так как выборки неравны, метрика accuracy не является приоритетной, так как в медицине более важно выявить именно группу людей, которая вернется. Для этого нам нужно увеличить **recall(retention=1)**, пожертвовав аккуратностью

Результаты новой модели

	precision	recall	f1-score
0	0.9376	0.3014	0.4561
1	0.1030	0.8000	0.1825
accuracy			0.3468
macro avg	0.5203	0.5507	0.3193
weighted avg	0.8615	0.3468	0.4312

BUSINESS INTERPETATION

После оптимизации порога классификации модель демонстрирует способность выявлять ~70% пациентов с риском реадмиссии. Несмотря на снижение accuracy, уменьшение количества ложно отрицательных прогнозов делает модель более полезной для клинического применения, где приоритетом является минимизация пропусков реадмиссии.

Выводы

- Важность смены лечения для людей с повышенным результатом теста статистически подтверждена.
- Значит мы отклоняем нулевую гипотезу и принимаем альтернативную, а именно, что возраст влияет на факт возвращение в больницу.
- Установлена взаимосвязь между интенсивностью лечения диабета в стационарных и его результатом.
- Сам факт проведения теста не влияет срок до следующей госпитализации пациента.

GP 3

Meet Our Team

МЕЗЕНЦЕВ РОМАН
2405

ПАНЧЕНКОВ НИКИТА
2405

БРЮХОВ СЕРГЕЙ
2405

САДКОВ ГЛЕБ
2405

КИРЬЯНОВА СОФЬЯ
2405

ЛЕОНИД РАХВАЛЬСКИЙ
2405

Thank You

for your time
and attention

Team 36