ГП №3. Statistics in Data Analysis

Егоров Андрей
Зуева Полина
Ионова Арина
Королев Александр
Михнюк Арсений
Чудайкин Игорь

Содержание презентации

	1 часть		2 часть
3	EDA	11-16	EDA
4	Формулировка статистических гипотез	17-22	Проверка гипотез
5	Исследование для проведения стат теста	23-25	Вычисление риска
6	Проведение стат теста		
7	Разница конверсий		
8	Bootstrap-анализ		
9	Бизнес-инсайты		

Первичный анализ данных и валидация эксперимента

Данные и метрика A/B-теста

294 478 наблюдений
290 584 уникальных пользователя
2 группы: old_page и new_page
Распределение по группам: ≈ 50 / 50
Выбранная метрика - Conversion Rate

Ключевые наблюдения EDA

Общая конверсия: ≈ 12%
CR(old_page) ≈ 12.10%
CR(new_page) ≈ 12.00%

Проверка корректности эксперимента

Обнаружены и удалены наблюдения, нарушающие условия теста
Проведён A/A-тест: z = −1.476; p-value = 0.1399

Формулировка статистических гипотез

I часть

В рамках A/B-теста сравниваются две версии посадочной страницы:

Control - старая версия страницы

Treatment - новая версия страницы

Цель эксперимента - определить, влияет ли новая версия страницы на конверсию пользователей.

В качестве ключевой метрики выбрана Conversion Rate - доля пользователей, совершивших целевое действие.

Обозначим:

pC -вероятность конверсии в контрольной группе

pT-вероятность конверсии в тестовой группе

Гипотезы:

H_0: pT=pC - новая версия не влияет на конверсию

H_1: pT≠pC - новая версия изменяет конверсию

Исследова
для выбор
статистич
теста

```
array([0, 1])
```

1. Переменная бинар
2. Определяем колич
3. Выборки являются
   одного пользовател
   более чем в одной

Согласно алгор

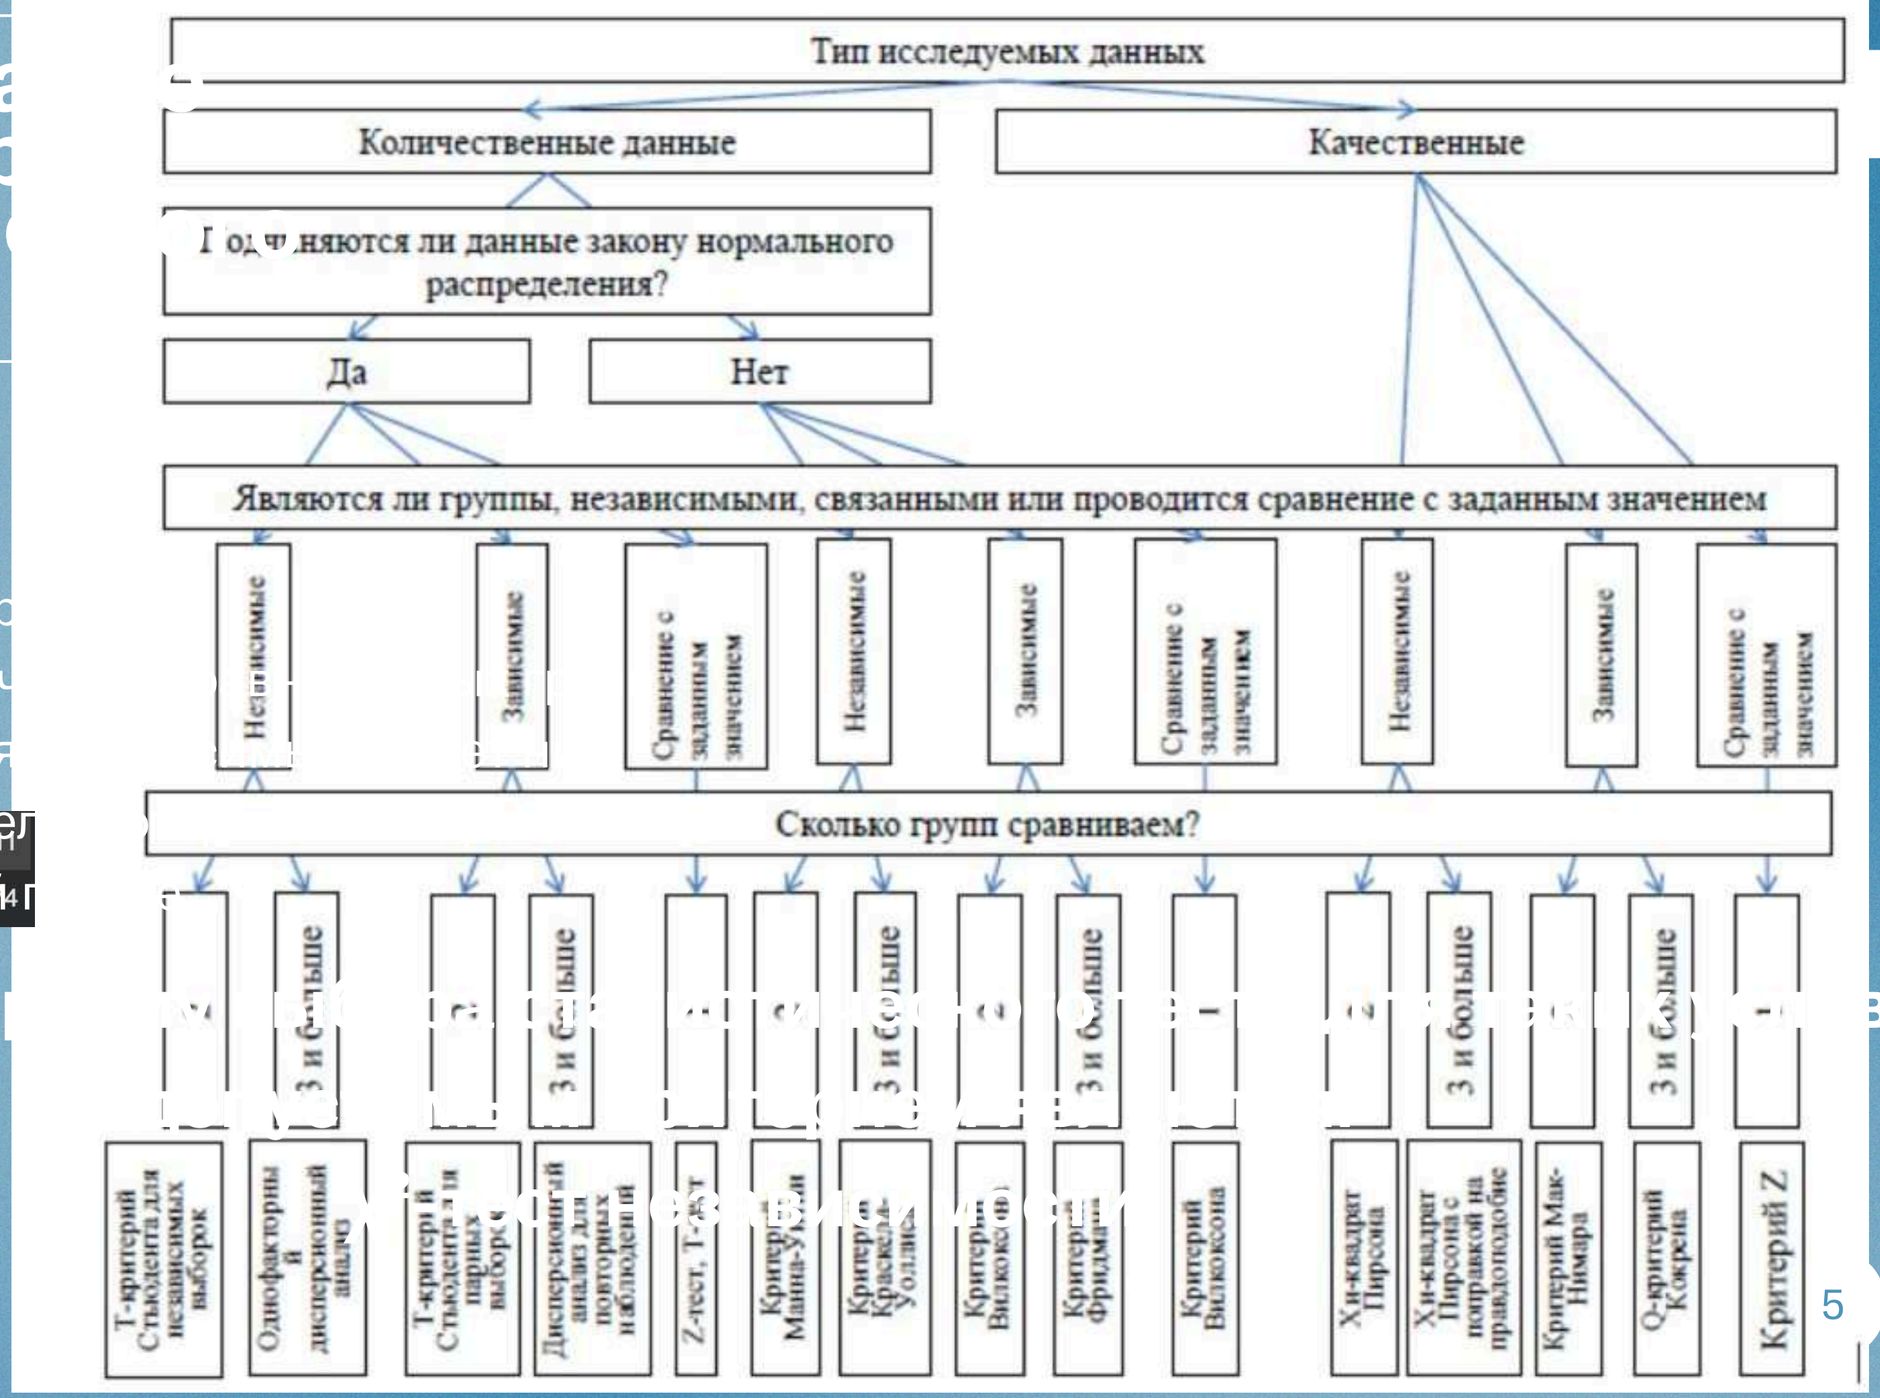

вий,

Проведение стат теста

I часть

Ход тестирования:

1. Построена таблица сопряжённости group × converted
2. Проверялась независимость принадлежности к группе и факта конверсии
3. Уровень значимости: α=0.05

Результаты теста:

```
chi2: 1.7053502645115002
dof: 1
p-value: 0.19158976298516003
```

p-value>α

Нулевая гипотеза не отвергается

Вывод:

Статистически значимых различий в конверсии между контрольной и тестовой группами на уровне значимости 5% не обнаружено

Эффект новой версии страницы не подтверждён

Разница конверсий

Перед началом анализа нужно зафиксировать параметр уровня значимости и метрику converted

```
Коэффициент конверсии контрольной группы: 0.1203863045004612
Коэффициент конверсии тестовой группы: 0.11881
Абсолютная разница: -0.00158
Относительная разница: -1.31%
```

Разница конверсий **не демонстрирует устойчивого смещения** в пользу какой-либо из групп. Относительно относительной разницы конверсий в среднем **новая версия страницы немного хуже старой,** однако величина этой разницы находится в пределах статистических отклонений.

Bootstrap-анализ

95%-й bootstrap доверительный интервал содержит ноль, что указывает на **отсутствие статистически значимого эффекта.** Результаты bootstrap анализа подтверждают выводы, полученные с помощью χ^2-теста.

```
Bootstrap 95%
CI: [-0.00393, 0.00073]
```

Bootstrap-анализ **подтверждает результаты предыдущих тестов** и демонстрирует, что независимо от выборки эффект колеблется вокруг нуля

Bootstrap

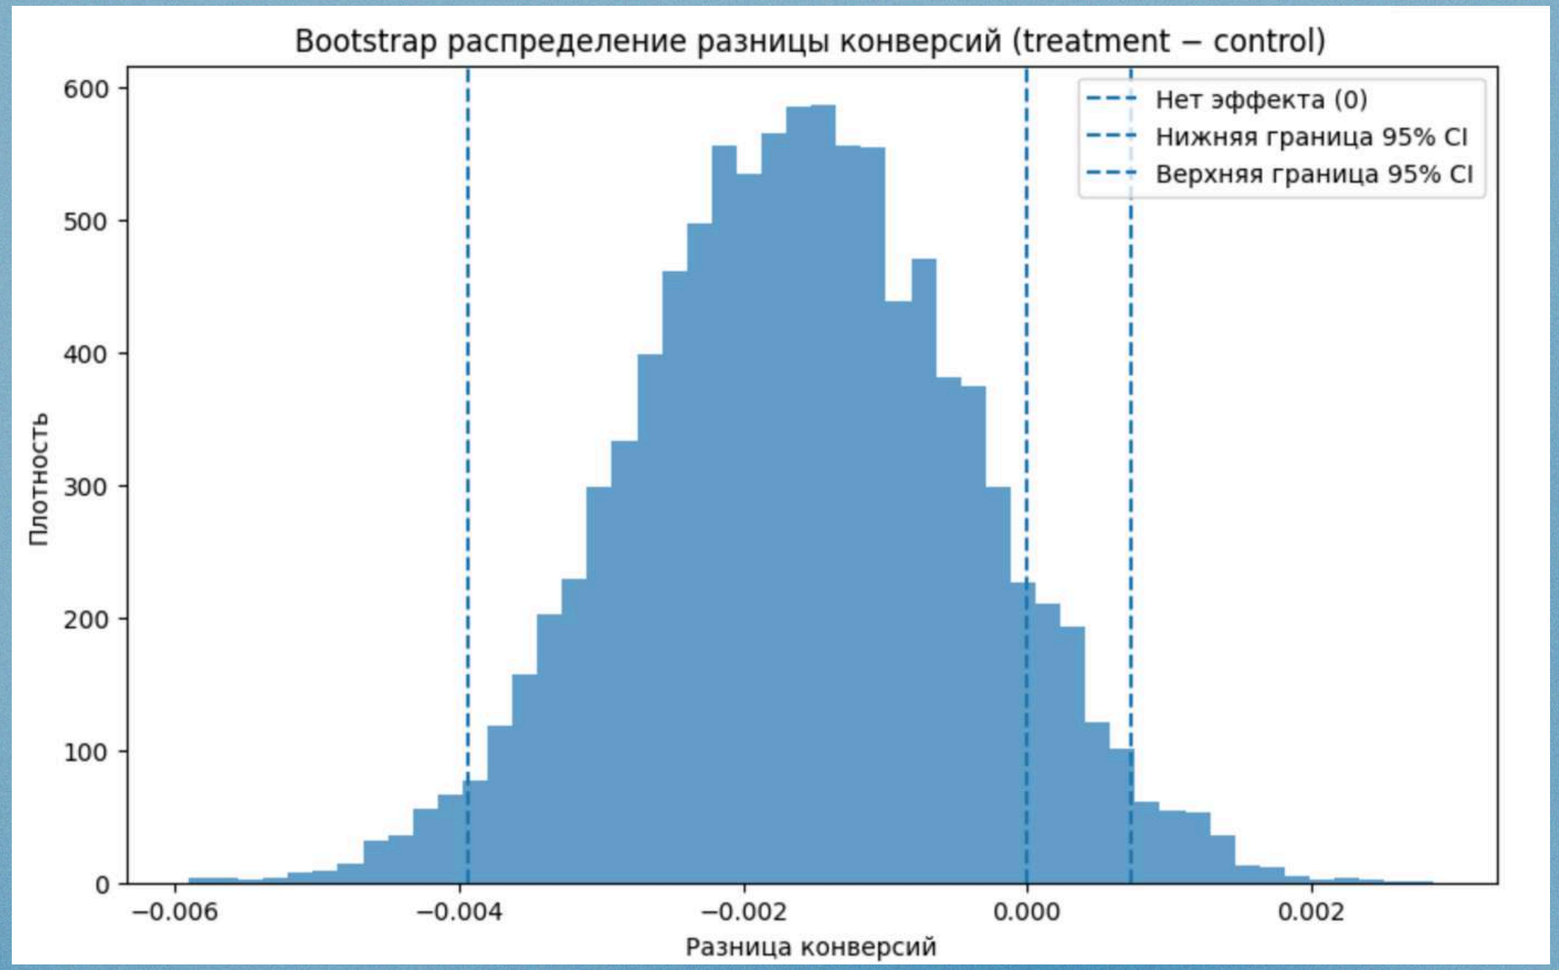

95% доверительный интервал покрывает как положительные, так и отрицательные значения,
что указывает на **отсутствие влияния** новой версии страницы на конверсию пользователей.

Вероятность положительного эффекта: 9.31%

Риск ухудшения ключевой метрики

Бизнес-инсайты

1.Новая версия страницы неэффективна. Новая версия не увеличивает вовлеченность пользователей, значит изменения не затрагивают ключевые факторы принятия решения или они уже адаптированы к текущему интерфейсу, и новая версия не увеличивает ценность

2.Результат устойчив и эксперимент был проведён корректно. Отсутствие эффекта это реальный результат эксперимента, на который можно точно опираться.

3.Высокий риск негативного влияния. Внедрение новой версии страницы имеет риск ухудшения конверсии, так как вероятность отрицательного эффекта превышает 90%.

2 часть

EDA (diabetes)

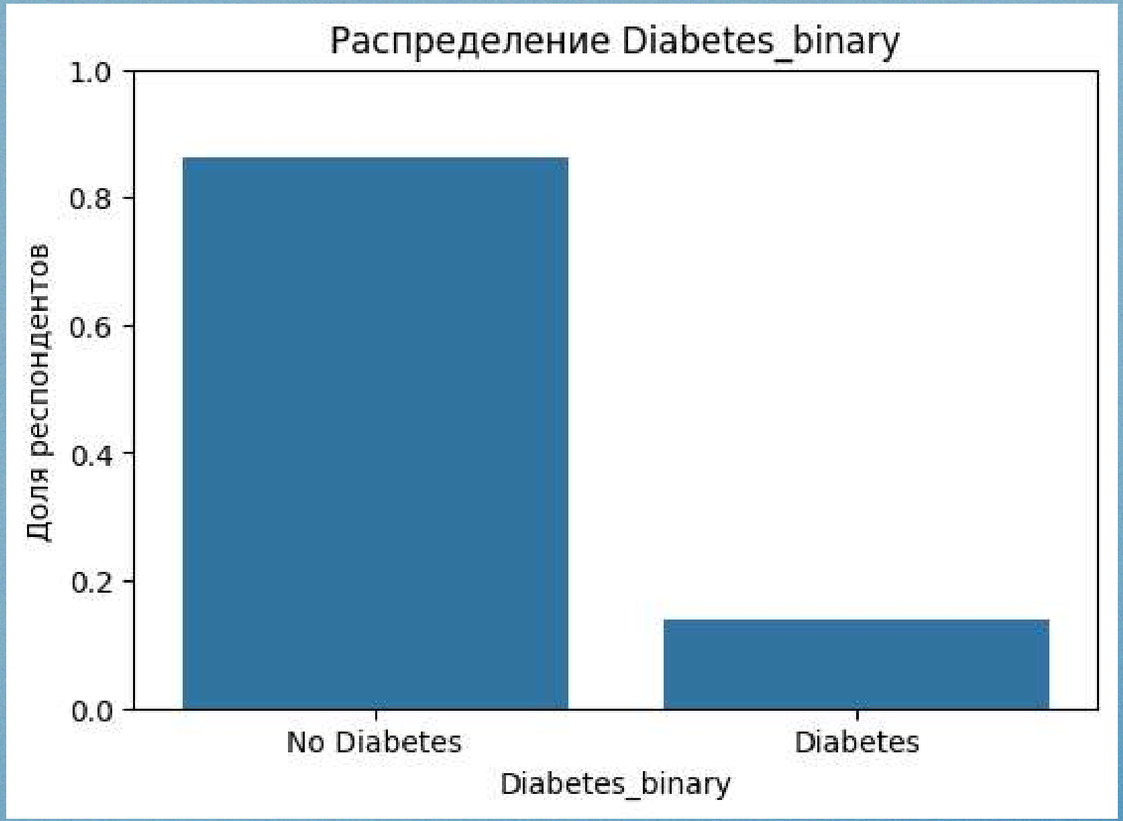

14 % людей с диабетом
35346
86 % людей без диабета
218334

2 часть

EDA (diabetes)

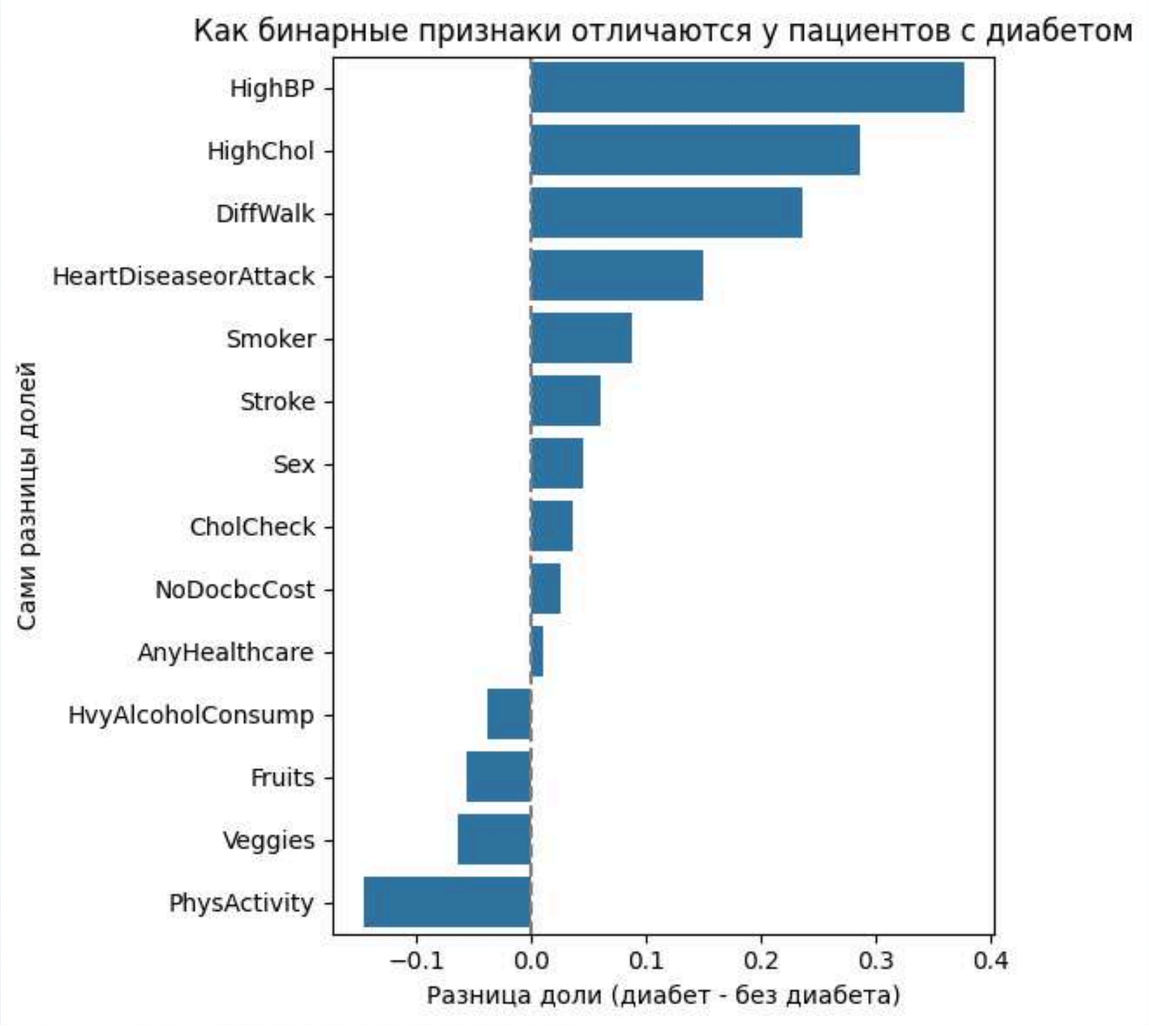

2 часть

EDA (diabetes)

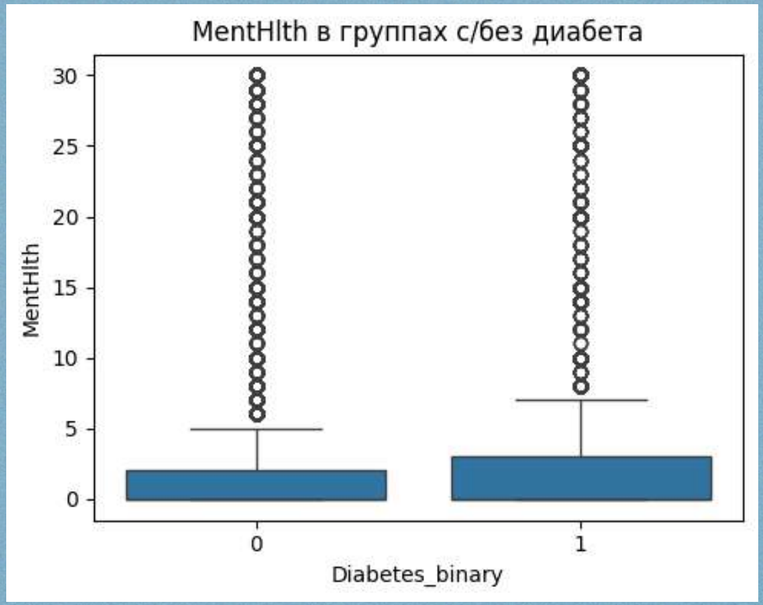

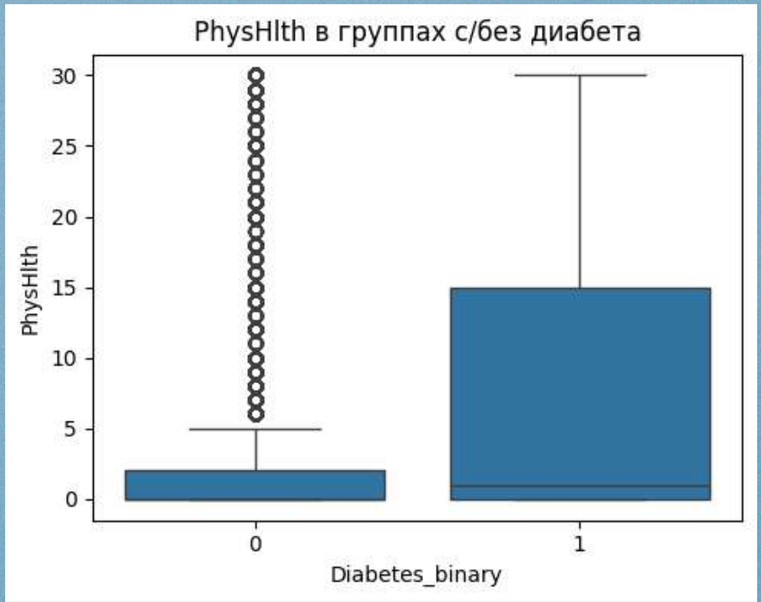

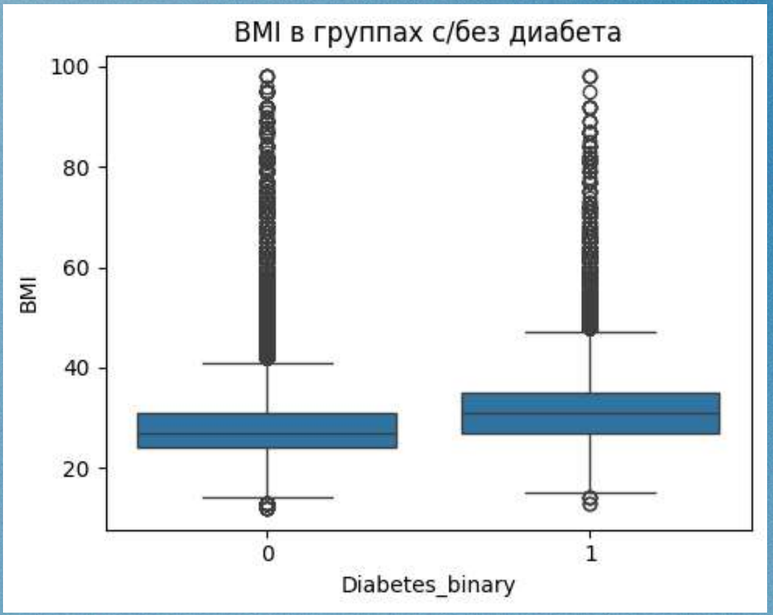

2 часть

EDA (diabetes)

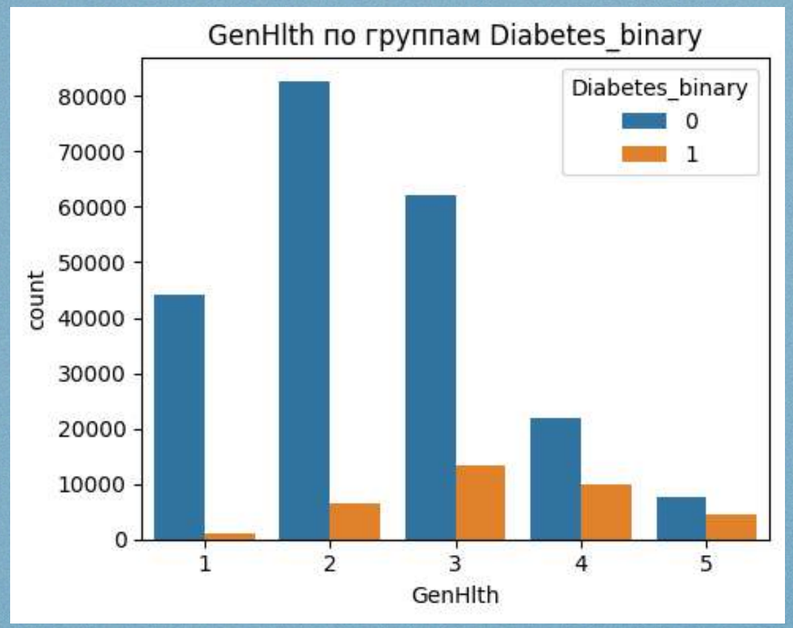

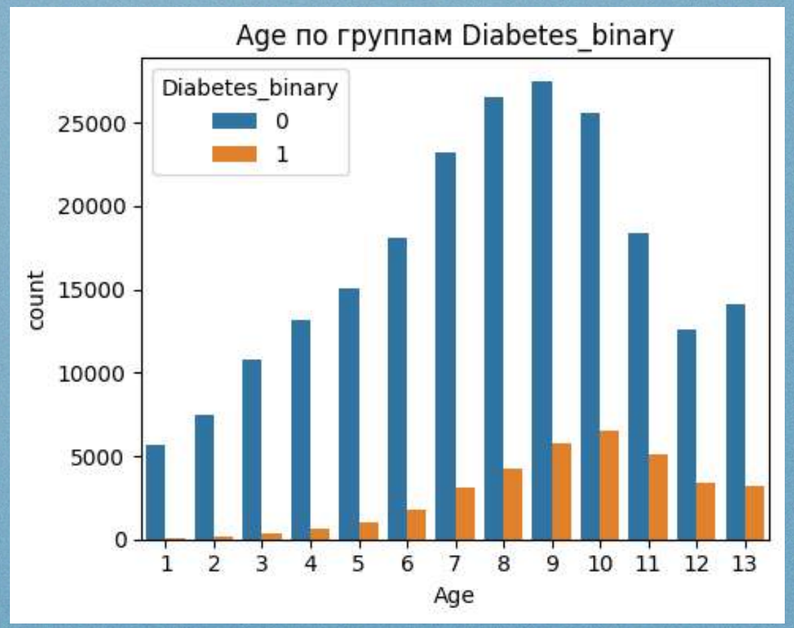

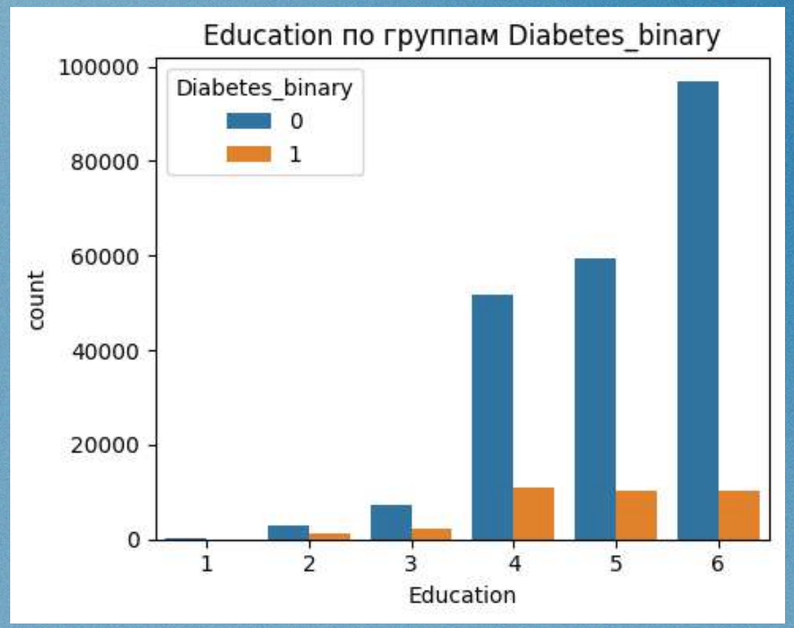

2 часть

EDA (diabetes)

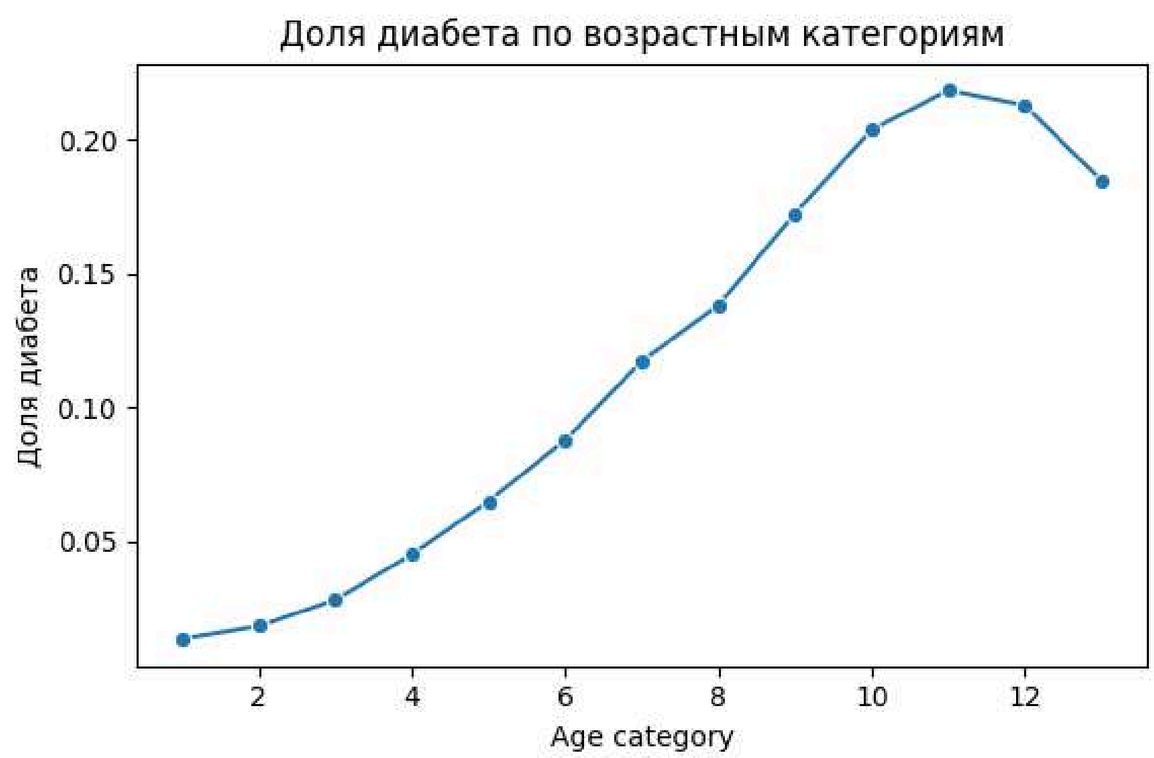

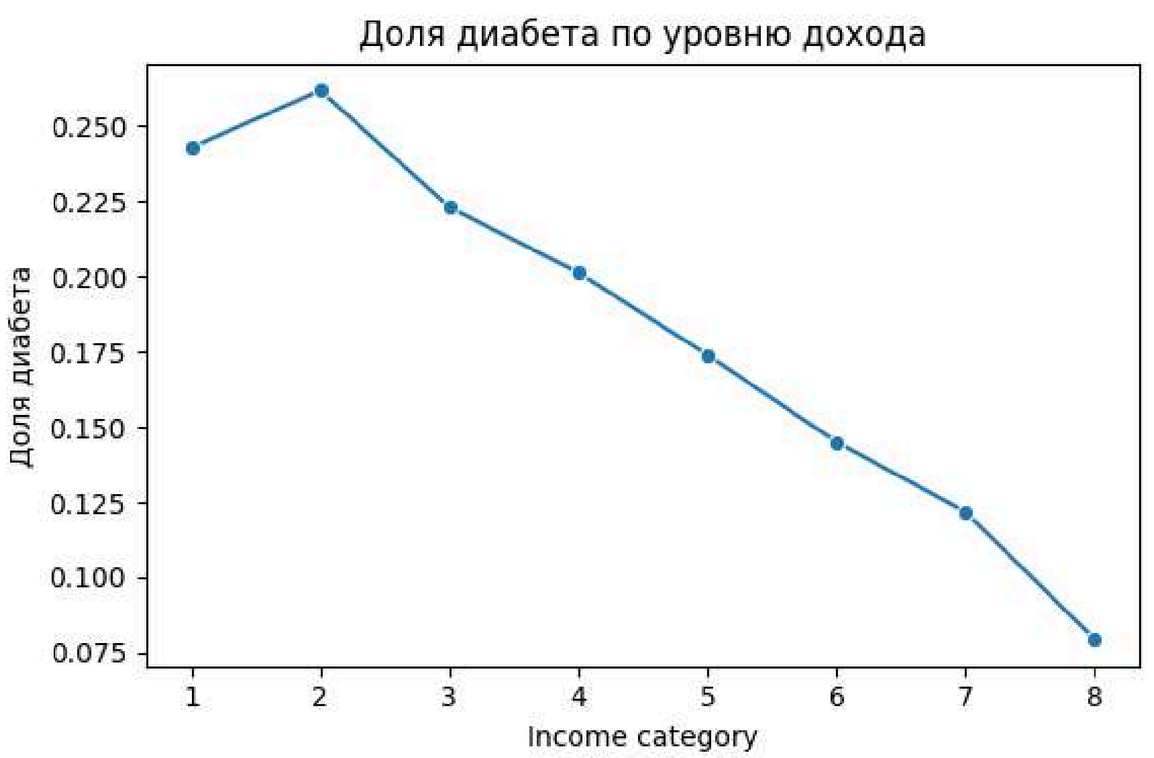

Новые признаки

1) Флаг по ожирению

2) Более общие категории по возрастам

3) Дискретно по доходу

4) Соц индекс как сумма образования и дохода

5) Индекс по образу жизни

6) Индекс по сердечным проблемам

7) Супер-генеральное число по каждому человеку

Obese и Диабет

Нулевая и альтернативная гипотезы:

H_0: наличие диабета не связано с ожирением (Obese_flag).

H_1: у людей с ожирением доля диабета выше, чем у людей без ожирения.

В выборке доля респондентов с диабетом среди лиц без ожирения составляет 8.9%, тогда как среди лиц с ожирением — 23.4% (разница 14.5 п.п.). Согласно χ^2-тесту независимости для таблицы Obese_flag × Diabetes_binary (χ^2=10041.86, df=1, < 0.001) связь между ожирением и диабетом статистически значима.

Это означает, что наличие ожирения существенно повышает вероятность диабета в рассматриваемой выборки.

Diabetes_binary	0	1
Obese_flag		
0	151040	14789
1	67294	20557

H_0: наличие диабета не связано с ожирением (Obese_flag). отвергается

Образ жизни и диабет

Нулевая и альтернативная гипотезы:
H_0: средний Lifestyle_score одинаков у людей с диабетом и без.
H_1: у людей без диабета Lifestyle_score выше.

- Среднее значение Lifestyle_score у респондентов без диабета составляет x= 2.859 у респондентов с диабетом x= 2.58

- Результаты t-теста Уэлча показывают значимые различия средних (t = 51.77, df ≈ 47 699, p < 0.001): Lifestyle_score у респондентов с диабетом статистически значимо ниже, чем у респондентов без диабета.

- Непараметрический критерий Манна–Уитни также подтверждает наличие различий между группами (p < 0.001)

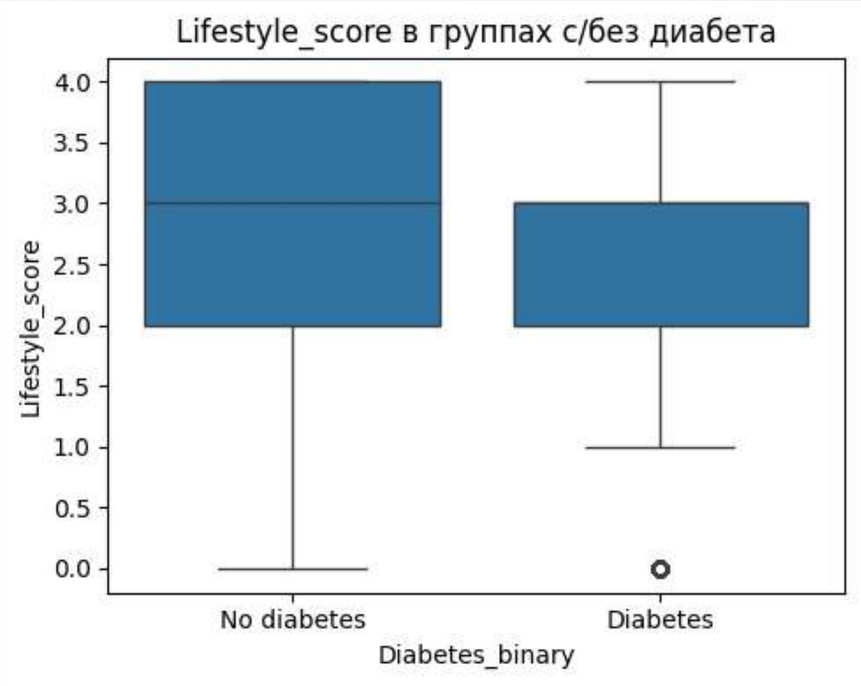

H_0: наличие диабета не связано с образом жизни. отвергается

2 часть

Соц. статус и диабет

Нулевая и альтернативная гипотезы:
H_0: средний soc_index одинаков у людей с диабетом и без.
H_1: у людей с диабетом soc_index ниже (ниже доход/образование).

- Для оценки связи социально-экономического статуса с диабетом был использован показатель soc_index (Income + Education).

- Результаты t-теста Уэлча показали значимые различия средних значений soc_index (t = 82.69, df ≈ 45 249, p<0,001): у респондентов без диабета средний soc_index выше, чем у респондентов с диабетом.

- Непараметрический критерий Манна–Уитни (альтернатива «диабетики < без диабета») также подтвердил этот результат (p<0,001)

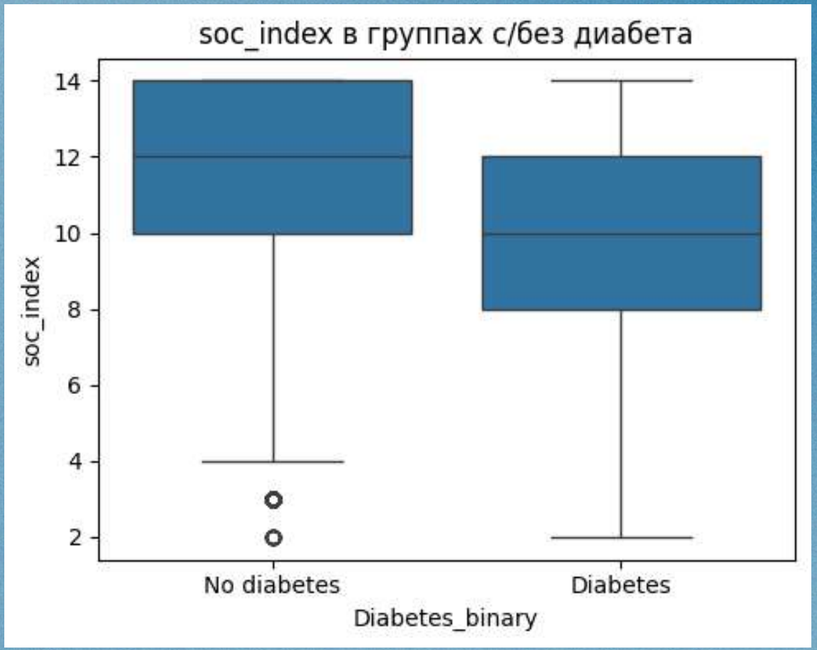

H_0: наличие диабета не связано с соц статусом. отвергается

Cardio problems и диабет

Нулевая и альтернативная гипотезы:
H_0: средний cardio_index одинаков у людей с диабетом и без.
H_1: у людей с диабетом средний cardio_index ниже, т.е. у них больше сердечно-сосудистых проблем.

- Чем выше значение индекса, тем лучше состояние сердечно-сосудистой системы.

- Среднее значение cardio_index у респондентов без диабета составило x=3.998, у респондентов с диабетом — x=2.891. Результаты теста (t=167.87, df≈45129, p<0.001) свидетельствуют о статистически значимом снижении cardio_index у респондентов с диабетом по сравнению с остальными.

- Непараметрический критерий Манна–Уитни (альтернатива «без диабета > диабет») также выявил значимые различия распределений (p<0.001).

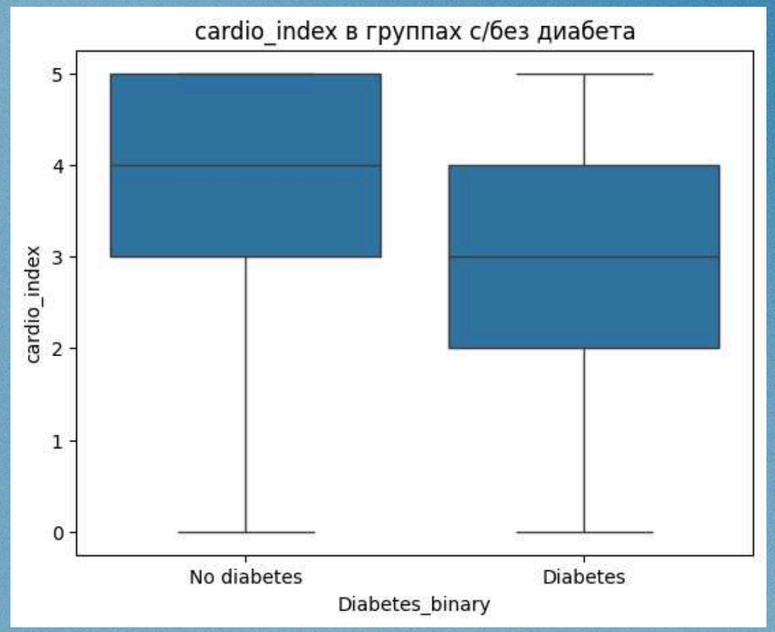

H_0: наличие диабета не связано с cardio problems. отвергается

Физическое здоровье и диабет

Нулевая и альтернативная гипотезы:
H_0: распределения физического здоровья у групп с диабетом и без одинаковы
H_1: у людей с диабетом дней с плохим самочувствием больше чем у людей без диабета

- Чем больше число тем больше дней с плохим самочувствием за последние 30 дней
- Среднее значение физического здоровья у людей без диабета составило 8 дней, у респондентов с диабетом - 4.
- Для окончательного опровержения нулевой гипотезы был проведён тест Манн-Витни, который подтвердил альтернативную гипотезу: у людей с диабетом больше дней с плохим самочувствием за период из 30 дней чем у людей без заболевания.

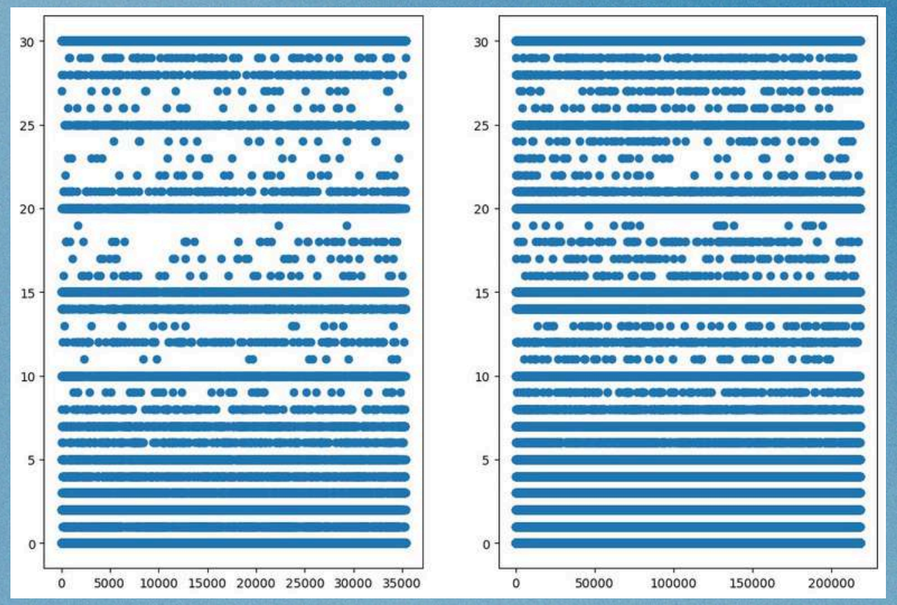

H_0: распределения физического здоровья у групп с диабетом и без одинаковы. отвергается

Возраст и риск диабета

Нулевая и альтернативная гипотезы:

H_0: нет монотонной связи между возрастной группой и наличием диабета

H_1: с ростом возрастной категории вероятность диабета увеличивается

- Чем больше номер группы тем старше человек, I группа - 18-35 лет, 2 группа - 35-50 лет, 3 группа - 50-65 лет, 4 группа - 65+ лет

- Доля людей с диабетом в первой группе - 2.23%, во второй - 9.35%, в третьей - 18.48%, в четвёртой - 25,88%

- Для окончательного опровержения нулевой гипотезы была найдена корреляция Спирмена, которая подтвердила альтернативную гипотезу: с ростом возраста вероятность диабета увеличивается.

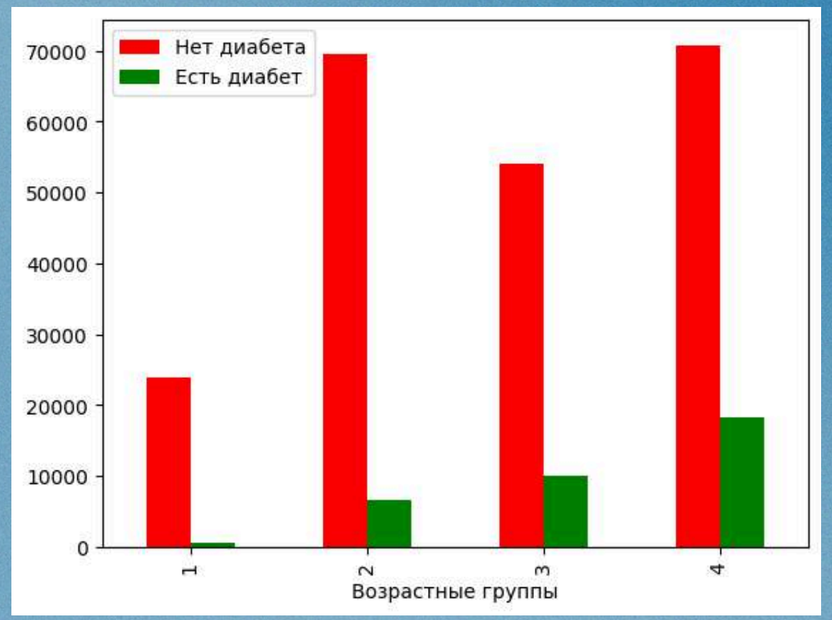

H_0: нет монотонной связи между возрастной группой и наличием диабета. отвергается

Вычисление риска развития диабета

Проверив достаточное количество статистических гипотез о связи целевой переменной **(наличие диабета)** с признаками из датасета, имеет смысл построить **предиктивную модель.**

Функция на основе **логистической регрессии** будет оценивать риски отдельного человека заболеть диабетом, а также предлагать конкретные факторы риска по весам логистической регрессии.

Пример:

На вход модели дан человек, ведущий **не очень здоровый образ жизни**.

Модель, обучившись на большой выборке людей, может утверждать, **какие факторы сыграют для человека в положительном ключе относительно заболевания диабетом** (то бишь защитят), **а какие - отрицательно** (то бишь повысят шансы на болезнь).

```
--- АНАЛИЗ ДЛЯ ПАЦИЕНТА ---
Всего признаков с положительным вкладом (Риск): 11
Всего признаков с отрицательным вкладом (Защита): 8

ТОП-5 ФАКТОРОВ РИСКА (повышают шанс диабета):
   Feature  Original_Value  Contribution
   GenHlth               3      1.748408
 CholCheck               1      1.348459
       BMI              22      1.102745
       Age               5      0.421658
Obese_flag               1      0.375240

ТОП-5 ЗАЩИТНЫХ ФАКТОРОВ (снижают шанс диабета):
      Feature  Original_Value  Contribution
 cardio_index               3     -1.231650
General_index               6     -0.693794
    soc_index               5     -0.587054
  Education_4               1     -0.379168
     Income_6               1     -0.144058
```

Пример:

Вероятность конкретно этого человека заболеть диабетом (согласно модели) равняется **68.7%, что вполне резонно**, согласно проделанному анализу и выявленным зависимостям.

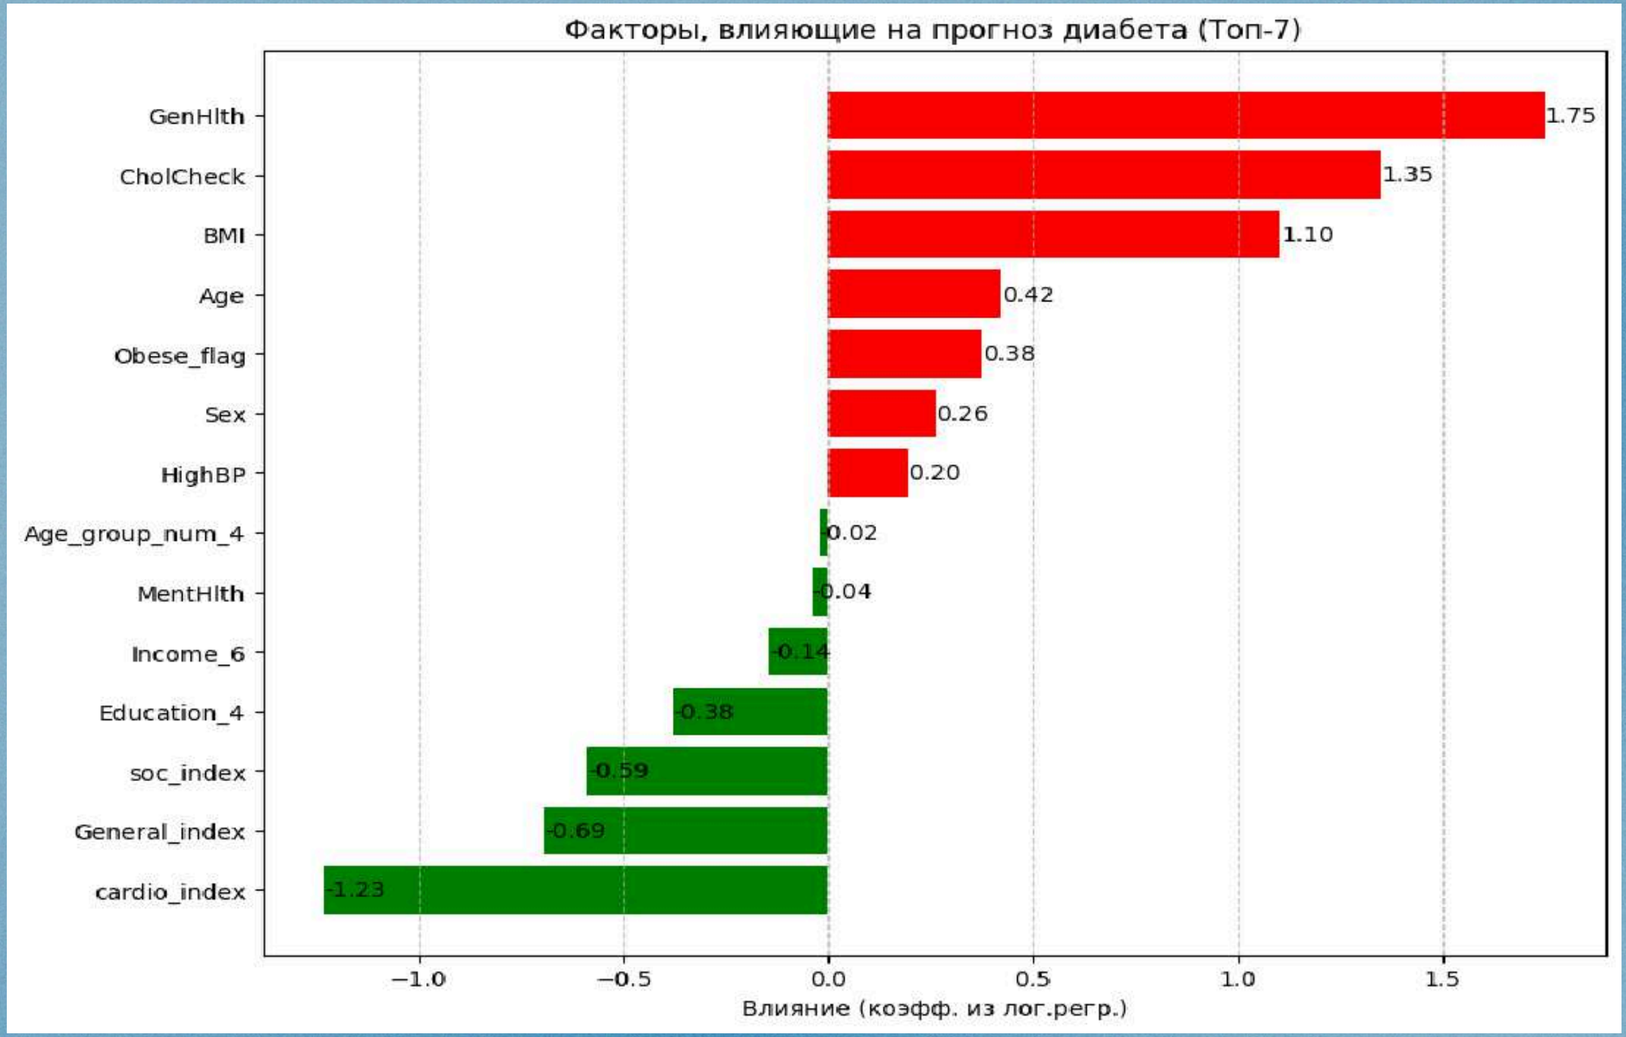

Бизнес-модель

2 часть

Ключевые партнёры

- Медицинские учреждения и клиники
- Страховые компании (ДМС)
- Корпоративные программы здоровья
- НКО и фонды в сфере профилактики заболеваний
- Государственные и региональные органы здравоохранения
- IT-партнёры и поставщики инфраструктуры

Ключевые ресурсы

- Датасеты и аналитическая база
- Модель оценки риска диабета
- Экспертиза в data science и статистике
- IT-инфраструктура
- Экспертиза в области здравоохранения и профилактики

Ключевые активности

- Анализ медицинских и социально-демографических данных
- Разработка и обновление предиктивной модели риска диабета
- Разработка цифрового продукта (web / mobile / API)
- Интерпретация результатов и формирование рекомендаций

Поддержка пользователей и B2B-клиентов

Ценностные предложения

Для B2C:

- Персональная оценка риска развития диабета
- Понятное объяснение факторов риска
- Персонализированные рекомендации по снижению риска
- Ранняя профилактика вместо позднего лечения

Для B2B:

- Инструмент скоринга риска диабета
- Аналитика по группам людей
- Поддержка программ профилактики и корпоративного здоровья